# Case-Study zur Arbeitslosigkeit in Deutschland

*Teil 2: Beschreiben, visualisieren, Zusammenhänge erkennen*



Downloading package: dplyr

# Rückblick und Ziele



Downloading package: readr

# Recap: Kahoot zu Teil 1

**kahoot.it** · PIN am Beamer

**Dieselben 7 Fragen wie am Ende von Teil 1.** Mal sehen, was hängen geblieben ist.

Tipp: Öffnen Sie die Folien jetzt schon auf Ihrem Laptop. Die Code-Felder (webR) laden im Hintergrund ca. 20 Sekunden.

- `pivot_longer()`-Fehlermeldung lesen
- wide → long
- Bug Hunt 5: der Join und die Zeilenzahl
- Einheiten: × 1.000, × 1e6
- 400 Landkreise und der letzte Check vor der Abgabe

Kahoot öffnen →

05:00



Downloading package: readr

# Schätzfrage zum Einstieg

**30 Sekunden, notieren Sie Ihren Tipp:**

- Welcher Landkreis hatte 2024 die **niedrigste** Arbeitslosenquote Deutschlands?
- Welcher die **höchste**?
- Auf welchem Platz liegt **Ulm**?

Auflösung, sobald wir die Quote berechnet haben.



Downloading package: ggplot2

# Organisatorische Hinweise

- Viele Deadlines
- Ungewohntes Format (sehr technisch)
- GitHub, RStudio, R
- Arbeitsschritte mit GitHub (3. Problem Set von GitHub herunterladen und lösen)

**Das ist alles neu, und das ist uns bewusst!**

**Warum das Ganze?**

- Durch die Deadlines setzen Sie sich kontinuierlich mit dem Stoff auseinander
- GitHub, R, RStudio und Quarto brauchen Sie in den Projekten → Üben mit RTutor
- Visualisierung, Interpretation und Präsentation sind in den Projekten gefragt → Üben mit der Case-Study
- Arbeiten mit KI → lernen, wo Chat AI Ihre Arbeit sinnvoll ergänzt und wo nicht



Downloading package: ggplot2

# Wo stehen wir?

**Teil 1** (✔): Daten beschaffen, bereinigen, prüfen → ein Datensatz `gesamtdaten` mit einer Zeile je Landkreis.

**Teil 2:** Was steht eigentlich in den Daten? Zwei Sitzungen:

- **Sitzung 1:** Grundlagen → Überblick → Tabellen
- **Sitzung 2:** Grafiken → Karten → Zusammenhänge

Ziele:

- Daten **beschreiben**: Kennzahlen und Tabellen (`skimr`, `kableExtra`)
- Daten **zeigen**: Verteilungen, Zeitreihen, Karten (`ggplot2`, `sf`, `plotly`)
- **Zusammenhänge** mit Korrelationen quantifizieren
- Tabellen und Grafiken **prüfen**, egal ob von Ihnen oder von Chat AI

> **Das eigentliche Lernziel von Teil 2**
>
> Tabellen und Grafiken **erstellen** kann Chat AI in Sekunden. Sie sollen sie **richtig lesen, ehrlich beschreiben und prüfen** können. Die 🐛 Bug Hunts (Nr. 6–10, weiter gezählt ab Teil 1) sind deshalb oft keine Code-Fehler, sondern **Denkfehler**: falscher Nenner, falsche Formel, falsche Legende, falsche Interpretation.

*Landkreis* steht im Folgenden für Landkreise **und** kreisfreie Städte (Kreisebene). Im dritten RTutor Problem Set visualisieren Sie Daten zu Ländern auf europäischer Ebene.

# Daten und Pakete laden

## Wir laden die in Teil 1 erstellten Datensätze:

```r
library(tidyverse)
library(skimr)
library(kableExtra)
library(sf)
library(plotly)

gesamtdaten   <- readRDS(file.path(datenpfad, "gesamtdaten.rds"))
bip_zeitreihe <- readRDS(file.path(datenpfad, "bip_zeitreihe.rds"))
landkreise    <- readRDS(file.path(datenpfad, "landkreise.rds"))   # Geodaten (sf)
bundesland    <- readRDS(file.path(datenpfad, "bundesland.rds"))   # Geodaten (sf)
```



Im RStudio-Projekt `case-study/` lautet der Pfad einfach `datenpfad <- "data"`.

# Grundlagen

**Grundlagen** → Überblick → Tabellen → Grafiken → Karten → Zusammenhänge

**Nach diesem Abschnitt können Sie …**

- eine Aussage als deskriptiv oder induktiv einordnen,
- die passenden Werkzeuge für eine bzw. zwei Variablen benennen,
- einen Boxplot lesen (Box, Whisker, Ausreißer).

# Deskriptive vs. induktive Statistik

- **Deskriptive** (beschreibende) Statistik beschreibt den vorliegenden Datensatz
- **Induktive** (schließende) Statistik schließt von einer Stichprobe auf die Grundgesamtheit

Aber:

- Die Formel für den Mittelwert ist in beiden Fällen dieselbe
- Der Datensatz kann derselbe sein

> **Worin genau besteht dann der Unterschied?**

# Deskriptive Statistik

## Deskriptiv

- Interesse gilt dem **Datensatz selbst**
- Beispiel: Arbeitslose aller Landkreise laut Arbeitsagentur (**Vollerhebung**)
- Darstellung als Tabelle oder Grafik

## Induktiv

- Interesse gilt der **Population**, beobachtet ist nur eine (zufällige) Stichprobe
- Beispiel: Mikrozensus, eine Befragung zufällig ausgewählter Haushalte
- Typische Ziele: **Vorhersage** und **kausale Zusammenhänge**

In die induktive Statistik tauchen wir nächstes Semester tiefer ein.

# Deskriptiv oder induktiv?

**Handzeichen:** deskriptiv ✋ oder induktiv ✌️?

1. “Bremerhaven hatte 2024 eine höhere Arbeitslosenquote als die Stadt Bremen.”
2. “Laut Mikrozensus ist der Anteil der Teilzeitbeschäftigten in Deutschland gestiegen.”
3. “Landkreise in Ostdeutschland haben im Mittel eine höhere Arbeitslosenquote als in Westdeutschland.”
4. “Eine Umfrage unter 300 Studierenden in Ulm zeigt: Studierende in Deutschland nutzen Chat AI täglich.”

01:00

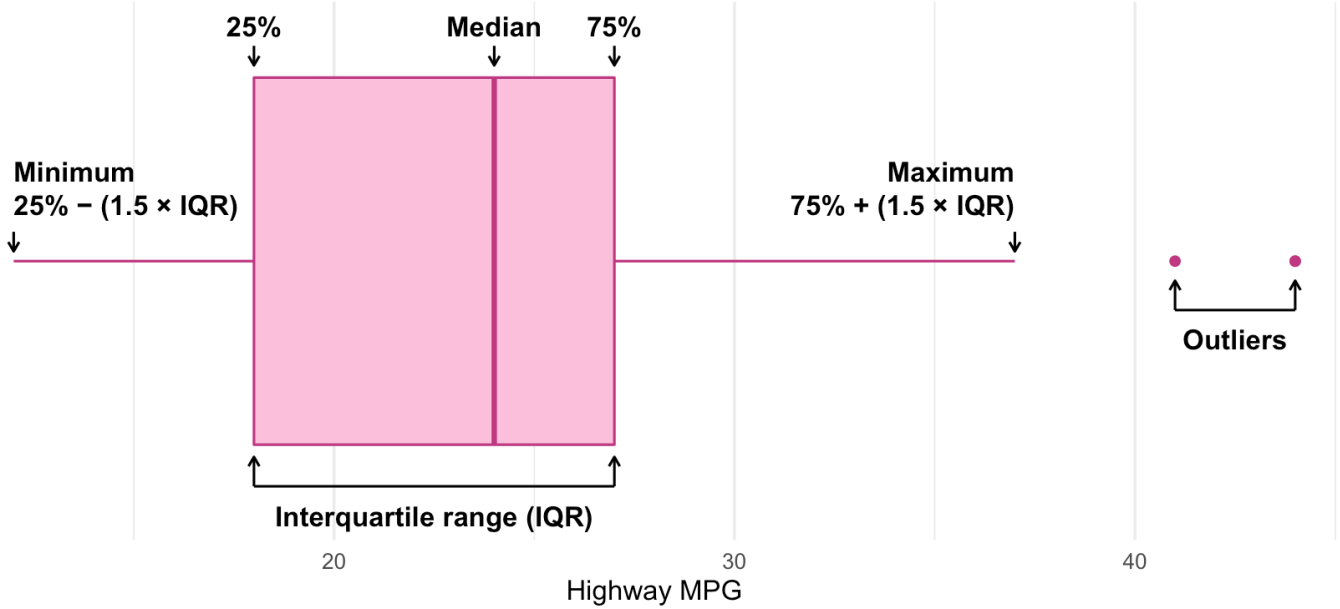
# Werkzeuge der deskriptiven Statistik

| | **Kennzahlen** | **Grafiken** |
|---|---|---|
| **Univariat** (eine Variable) | Mittelwert, Median, Standardabweichung, Quantile | Boxplot, Histogramm, Kerndichte |
| **Bivariat** (zwei Variablen) | Korrelationskoeffizient, Korrelationsmatrix | Streudiagramm |

Univariat: Überblick verschaffen, Eigenschaften einer Variablen aufzeigen.

Bivariat: Wenn sich eine Variable verändert, wie verändert sich die andere?

# Einen Boxplot lesen




🔮 **Prognose:** Welcher Anteil der Beobachtungen liegt in der Box? Ab wann wird ein Punkt einzeln gezeichnet?

- Box = 25 %- bis 75 %-Quantil → **die mittleren 50 %**
- Whisker: bis max. 1,5 × Interquartilsabstand (IQR)
- Punkte weiter als 1,5 × IQR von der Box entfernt: einzeln gezeichnete **Ausreißer**

# Überblick und Arbeitslosenquote

Grundlagen ✔ → **Überblick** → Tabellen → Grafiken → Karten → Zusammenhänge

**Nach diesem Abschnitt können Sie …**

- mit `skimr` in Sekunden einen Überblick über einen Datensatz gewinnen,
- fehlende Werte auf ihre Ursache zurückführen,
- prüfen, ob eine Kennzahl so definiert ist, wie Sie denken.

# Arbeitslosenquote berechnen

**Zuerst:** Überblick gewinnen. Wie viele Landkreise haben wir? Wie sind Schulden, Arbeitslosigkeit und BIP verteilt?

Dafür brauchen wir zuerst die Arbeitslosenquote:

$$\text{Arbeitslosenquote} = \frac{\text{Arbeitslose}}{\text{Erwerbstätige} + \text{Arbeitslose}} \times 100$$

```
1 gesamtdaten <- gesamtdaten |>
2   mutate(alo_quote = total_alo / (erw + total_alo) * 100)
```

# Ein erster schneller Blick

**Quick and dirty:** Wie viele Erwerbstätige und Einwohner hat Deutschland laut unseren Daten?

```r
gesamtdaten |>
  summarise(total_erw = sum(erw, na.rm = TRUE), total_einwohner = sum(Einwohner, na.rm = TRUE))
```

```
# A tibble: 1 × 2
  total_erw total_einwohner
      <dbl>           <dbl>
1  45987000        77277808
```

> Deutschland hat knapp 84 Mio. Einwohner. Wir kommen auf **77,3 Mio.** Wer fehlt?

# Wer fehlt?

```r
gesamtdaten |>
  filter(is.na(Einwohner) | is.na(alo_quote)) |>
  select(Regionalschluessel, landkreis_name, Einwohner, erw, bip, alo_quote)
```

```
# A tibble: 4 × 6
  Regionalschluessel landkreis_name Einwohner     erw          bip alo_quote
  <chr>              <chr>              <dbl>   <dbl>        <dbl>     <dbl>
1 02000              Hamburg               NA 1358514 162843535000      6.11
2 04011              Bremen                NA  383383  36111353000      7.72
3 04012              Bremerhaven           NA   61816   5156070000     12.8
4 11000              Berlin                NA 2197430 208449010000      8.47
```

> Ist das eine **Eigenschaft der Daten** oder ein **Fehler**?

**Eigenschaft der Daten:** `Einwohner` kommt aus der Schuldenstatistik der *Gemeinden*. Die Schulden der Stadtstaaten sind Landesschulden und stehen dort nicht drin.

> `NA` ist nicht automatisch ein Fehler. Aber Sie sollten für **jedes** `NA` sagen können, *warum* es da ist.

# 🔁 Erinnern Sie sich? Sonderfall Stadtstaaten

**30 Sekunden, Handzeichen:** In Teil 1 haben wir vor dem Merge `stadtstaaten_als_kreis()` eingefügt. Was wäre **ohne** diesen Schritt mit Hamburg und Berlin passiert?

**(a)** Fehlermeldung **(b)** Warnung **(c)** Die Zeilen fallen weg **(d)** BIP und Erwerbstätige werden still `NA`

**(d)**: Im BIP-Datensatz heißen sie nur `02` und `11`, in den Arbeitslosendaten `02000` und `11000`. `left_join()` findet keinen Partner und meldet **nichts**.

**Nach jedem Join:** `colSums(is.na())` **und** fragen, *welche* Zeilen `NA` sind. Fehlen bekannte, große Einheiten (Hamburg! Berlin!), ist es fast nie eine Eigenschaft der Daten.

# Überblick mit `skimr`

Etwas besser als `summarise()`: `skimr` liefert für alle Variablen auf einmal einen Überblick.

```
gesamtdaten |>
  select(alo_quote, Schulden_pro_kopf_lk, bip_pro_kopf, landkreis_name) |>
  skim_without_charts() |>
  yank("character")
```

## Variable type: character

| skim_variable | n_missing | complete_rate | min | max | empty | n_unique | whitespace |
|---|---|---|---|---|---|---|---|
| landkreis_name | 0 | 1 | 3 | 32 | 0 | 378 | 0 |

400 Beobachtungen, aber nur **378** verschiedene Namen. Woher kommt das?

# Zwei Mal “München”?

```r
gesamtdaten |>
  filter(landkreis_name %in% c("München", "Augsburg", "Würzburg")) |>
  select(Regionalschluessel, landkreis_name, bundesland_name) |>
  print(n = 6)
```

```
# A tibble: 6 × 3
  Regionalschluessel landkreis_name bundesland_name
  <chr>              <chr>          <chr>
1 09162              München        Bayern
2 09184              München        Bayern
3 09663              Würzburg       Bayern
4 09679              Würzburg       Bayern
5 09761              Augsburg       Bayern
6 09772              Augsburg       Bayern
```

- `09162` ist die **Stadt** München, `09184` der **Landkreis** München
- Gleicher Name, anderer Regionalschlüssel → zwei Beobachtungen
- Das betrifft 44 Zeilen

**Darum mergen wir immer über den Schlüssel, nie über Namen.**

# Stimmen die 400 Beobachtungen?

> **Wie viele Landkreise und kreisfreie Städte hat Deutschland?**

- 294 Landkreise
- 106 kreisfreie Städte
- Zusammen: **400** ✔

Das ist Prüfschritt 7 der Checkliste aus Teil 1: **eine Zahl, die Sie aus einer anderen Quelle kennen.**

# Die numerischen Variablen

```
gesamtdaten |>
  select(alo_quote, Schulden_pro_kopf_lk, bip_pro_kopf) |>
  skim_without_charts() |>
  yank("numeric")
```

### Variable type: numeric

| skim_variable | n_missing | complete_rate | mean | sd | p0 | p25 | p50 | p75 | p100 |
|---|---|---|---|---|---|---|---|---|---|
| alo_quote | 0 | 1.00 | 5.61 | 2.09 | 1.88 | 4.00 | 5.44 | 6.90 | 14.46 |
| Schulden_pro_kopf_lk | 4 | 0.99 | 3223.38 | 2359.84 | 188.23 | 1660.58 | 2513.91 | 4041.37 | 18911.35 |
| bip_pro_kopf | 0 | 1.00 | 47951.45 | 19941.49 | 21480.73 | 36300.64 | 42721.06 | 52178.33 | 193293.12 |

**5 Minuten, zu zweit:** Wählen Sie **eine** Variable und beschreiben Sie sie in eigenen Worten: Mittelwert, Standardabweichung, Median. Was sagt das Verhältnis von Mittelwert zu Median?

05:00

# Die Tabelle beschrieben

**Arbeitslosenquote**

- Mittelwert: **5,61 %**
- SD: 2,09 Prozent**punkte** → deutliche regionale Unterschiede
- Median: 5,44 % → nahe am Mittelwert, kaum extreme Ausreißer

**Schulden pro Kopf**

- Mittelwert: **3.223 €**
- SD: 2.360 € → sehr hohe Streuung
- Median: 2.514 € → deutlich darunter: einige sehr hoch verschuldete Kreise ziehen den Mittelwert hoch

**BIP pro Kopf**

- Mittelwert: **47.951 €**
- SD: 19.941 € → hohe Streuung
- Median: 42.721 € → darunter: einige sehr reiche Kreise (Wolfsburg, Ingolstadt, …)

Mittelwert deutlich über dem Median → **rechtsschiefe Verteilung.** Ein Histogramm zeigt das gleich auf einen Blick.

# Auflösung: höchste und niedrigste Quote

```r
gesamtdaten |>
  slice_min(alo_quote, n = 3) |>
  select(Regionalschluessel, landkreis_name, alo_quote)
```

```
# A tibble: 3 × 3
  Regionalschluessel landkreis_name alo_quote
  <chr>              <chr>              <dbl>
1 09184              München             1.88
2 08421              Ulm                 2.28
3 09779              Donau-Ries          2.31
```

```r
gesamtdaten |>
  slice_max(alo_quote, n = 3) |>
  select(Regionalschluessel, landkreis_name, alo_quote)
```

```
# A tibble: 3 × 3
  Regionalschluessel landkreis_name alo_quote
  <chr>              <chr>              <dbl>
1 05513              Gelsenkirchen       14.5
2 04012              Bremerhaven         12.8
3 05112              Duisburg            12.7
```

- Platz 1 ist der **Landkreis** München (`09184`), nicht die Stadt. Daher: immer über den Schlüssel!
- Platz 2: **Ulm**. Merken Sie sich das. Gleich sehen wir, warum Ulm so gut dasteht.

# Konsistenzcheck gegen die amtliche Quote

Die Bundesagentur für Arbeit meldet für 2024 eine Arbeitslosenquote von **6,0 %** im Jahresdurchschnitt (Quelle: BA, Jahresrückblick 2024). Und wir?

```
gesamtdaten |>
  summarise(quote_deutschland = sum(total_alo) / sum(erw + total_alo) * 100)
```

```
# A tibble: 1 × 1
  quote_deutschland
              <dbl>
1              5.71
```

Erst summieren, dann teilen (wie in Bug Hunt 4 aus Teil 1): **5,71 %**. Nah dran, aber zu niedrig.

> **Woher kommt der Rest? Schauen wir uns den Nenner genauer an.**

# Bug Hunt 6: Mehr Erwerbstätige als Einwohner?

Unsere Quote: `total_alo / (erw + total_alo)`. Hier das Verhältnis von Erwerbstätigen (`erw`) zu Einwohnern:

```
gesamtdaten |>
  mutate(erw_je_ew = erw / Einwohner) |>
  filter(!is.na(erw_je_ew)) |>
  arrange(desc(erw_je_ew)) |>
  select(landkreis_name, erw, Einwohner, erw_je_ew, alo_quote) |>
  slice(c(1:3, (n() - 2):n())) |>     # die drei höchsten und die drei niedrigsten
  print(n = 6)
```

```
# A tibble: 6 × 5
  landkreis_name       erw Einwohner erw_je_ew alo_quote
  <chr>              <dbl>     <dbl>     <dbl>     <dbl>
1 Schweinfurt        66062     54193     1.22       2.98
2 Regensburg        168660    150678     1.12       2.37
3 Passau             55698     52974     1.05       3.15
4 Rhein-Pfalz-Kreis  44112    155807     0.283      7.68
5 Kusel              19470     69623     0.280      8.29
6 Südwestpfalz       23534     90294     0.261      8.88
```

**2 Minuten, zu zweit:** Wie kann ein Kreis **mehr Erwerbstätige als Einwohner** haben? Was bedeutet das für unsere Quote in Schweinfurt und in der Südwestpfalz?

# 🐛 Bug Hunt 6: Auflösung

- Arbeitslose werden am **Wohnort** gezählt, Erwerbstätige (VGR) am **Arbeitsort**
- Schweinfurt: viele **Einpendler:innen** → großer Nenner → Quote **zu niedrig**
- Südwestpfalz: viele **Auspendler:innen** (nach Pirmasens, Kaiserslautern) → kleiner Nenner → Quote **zu hoch**

> ⓘ Die Formel ist mathematisch richtig, aber **Zähler und Nenner passen nicht zusammen**. Die BA rechnet mit Erwerbspersonen am Wohnort. Diese Zahl haben wir auf Kreisebene nicht.

# ✍️ Jetzt Sie: der Pendler-Check

Wenden Sie das auf **Baden-Württemberg** an: `erw_je_ew` berechnen, absteigend sortieren. Wo liegen **Ulm** und der **Alb-Donau-Kreis**, der Ulm umschließt?

Exercise | Start Over | Show Hint | ▷ Run Code

```
gesamtdaten |>
  filter(bundesland_name == "Baden-Württemberg") |>
  mutate(erw_je_ew = ______) |>
  arrange(______) |>
  select(landkreis_name, erw_je_ew, alo_quote) |>
  print(n = 44)
```

04:00

# 🐛 Bug Hunt 6: Was lernen wir?

- Unsere Quote ist eine **Näherung**: Für Städte und ihr Umland ist sie verzerrt, auch für die Stadtstaaten. Für große Regionen (Ost/West, Flächenländer) gleichen sich Ein- und Auspendler weitgehend aus.
- Dieselbe Verzerrung steckt in **jeder** Kennzahl, die Arbeitsort- und Wohnort-Größen mischt, z.B. im BIP pro Kopf.

> ⓘ Chat AI berechnet Ihnen jede Kennzahl, die Sie verlangen. Ob **Zähler und Nenner zusammenpassen** (gleiches Gebiet, gleiches Jahr, gleiche Zählweise), müssen Sie prüfen: **Dokumentation der Quelle lesen.**

# Kahoot-Checkpoint 1: Überblick

**kahoot.it** · PIN am Beamer

## 6 Fragen, 5 Minuten

- deskriptiv oder induktiv?
- Boxplot lesen
- Mittelwert vs. Median: was heißt “rechtsschief”?
- Stadtstaaten: der stille Join
- Zwei Mal München
- Bug Hunt 6: Wohnort vs. Arbeitsort

Kahoot öffnen →

05:00

# Deskriptive Tabellen

Grundlagen ✔ → Überblick ✔ → **Tabellen** → Grafiken → Karten → Zusammenhänge

**Nach diesem Abschnitt können Sie …**

- Kennzahlen je Gruppe mit `group_by()` und `summarise()` berechnen,
- eine Tabelle mit `kableExtra` ansprechend gestalten,
- prüfen, ob eine Kennzahl das misst, was in der Überschrift steht.

# Arbeitslosenquote auf Bundeslandebene

Gibt es deutliche Unterschiede zwischen den Bundesländern? Wir aggregieren die Landkreise je Bundesland.

```
bula_data <- gesamtdaten |>
  group_by(bundesland_name) |>
  summarise(mean_alo   = mean(alo_quote),
            sd_alo     = sd(alo_quote),
            median_alo = median(alo_quote))
```

🔮 **Prognose:** Welches Bundesland hat die **höchste** mittlere Arbeitslosenquote? Und wo landet Baden-Württemberg?

# Vom Tibble zur Tabelle

```
bula_data |>
  arrange(mean_alo) |>
  kbl(col.names = c("Bundesland", "Mittelwert", "SD", "Median"),
      digits = 2) |>
  kable_styling(font_size = 14) |>
  kable_paper(full_width = FALSE) |>
  row_spec(c(8, 9, 10, 12, 13), bold = TRUE, color = "white", background = "#BBBBBB") |>
  add_header_above(c(" " = 1, "Arbeitslosenquote" = 3)) |>
  footnote(general = "Die ostdeutschen Bundesländer sind grau hinterlegt.",
           general_title = "Bitte beachten: ")
```

| Funktion | macht … |
|---|---|
| `kbl()` | Tibble → HTML-Tabelle, Spaltennamen, Rundung |
| `kable_styling()` | Schriftgröße, Layout |
| `row_spec()` | einzelne Zeilen hervorheben |
| `add_header_above()` | Überschrift über mehrere Spalten |
| `footnote()` | Fußnote |

Das Ergebnis sehen Sie auf der nächsten Folie.

# Bug Hunt 7: Was stimmt nicht?

Das ist der Code von eben. Er stammt aus der Vorlesung im letzten Jahr und lief damals einwandfrei. Dieses Jahr läuft er auch: ohne Fehler, ohne Warnung.

**2 Minuten, zu zweit:** Lesen Sie die Fußnote und dann die grauen Zeilen. Was ist falsch? **Warum** war es letztes Jahr richtig?

| Bundesland | Mittelwert | SD | Median |
|---|---|---|---|
| Bayern | 3.60 | 0.80 | 3.51 |
| Baden-Württemberg | 4.10 | 0.83 | 4.12 |
| Hessen | 5.50 | 1.28 | 5.61 |
| Rheinland-Pfalz | 5.84 | 1.52 | 5.68 |
| Schleswig-Holstein | 5.98 | 0.80 | 6.12 |
| Hamburg | 6.11 | NA | 6.11 |
| Niedersachsen | 6.18 | 1.77 | 6.37 |
| **Saarland** | **6.33** | **1.85** | **5.89** |
| **Sachsen** | **6.47** | **0.88** | **6.27** |
| **Thüringen** | **6.68** | **1.64** | **6.12** |
| Brandenburg | 7.06 | 1.63 | 7.19 |
| **Nordrhein-Westfalen** | **7.36** | **2.33** | **6.94** |
| **Mecklenburg-Vorpommern** | **7.94** | **1.20** | **8.26** |
| Sachsen-Anhalt | 8.09 | 1.48 | 7.89 |
| Berlin | 8.47 | NA | 8.47 |
| Bremen | 10.24 | 3.56 | 10.24 |

*Bitte beachten:*
Die ostdeutschen Bundesländer sind grau hinterlegt.

02:00

# Bug Hunt 7: Prüfung

In welchen Zeilen stehen die ostdeutschen Länder wirklich?

```
bula_tabelle |>
  mutate(zeile = row_number()) |>
  filter(bundesland_name %in% ost_laender) |>
  select(zeile, bundesland_name, mean_alo) |>
  print(n = 5)
```

```
# A tibble: 5 × 3
  zeile bundesland_name        mean_alo
  <int> <chr>                     <dbl>
1     9 Sachsen                    6.47
2    10 Thüringen                  6.68
3    11 Brandenburg                7.06
4    13 Mecklenburg-Vorpommern     7.94
5    14 Sachsen-Anhalt             8.09
```

- `row_spec(c(8, 9, 10, 12, 13))` war **per Hand abgezählt**.
- Durch die Stadtstaaten-Korrektur steht Hamburg jetzt auf Platz 6, alles darunter verschiebt sich.
- Dieselbe Falle wie in Teil 1: `sheet_names[7:19]`, `[1:7]`, `data_alo[-c(1, 2), ]`.

**Nie per Hand abzählen.** Zeilen und Spalten über ihren **Inhalt** auswählen, nicht über ihre **Position**.

# ✍️ Jetzt Sie: Bug Hunt 7 reparieren

`bula_tabelle` ist die sortierte Tabelle, `ost_laender` der Vektor mit den fünf ostdeutschen Ländern. Berechnen Sie `ost_zeilen` so, dass sie **immer** stimmen, egal wie die Tabelle sortiert ist.

Exercise | Start Over | Show Hint | ▷ Run Code

```
1 ost_zeilen <- c(8, 9, 10, 12, 13)
2
3 bula_tabelle$bundesland_name[ost_zeilen]
```

04:00

# Die korrigierte Tabelle

| | Arbeitslosenquote | | |
|---|---|---|---|
| **Bundesland** | **Mittelwert** | **SD** | **Median** |
| Bayern | 3.60 | 0.80 | 3.51 |
| Baden-Württemberg | 4.10 | 0.83 | 4.12 |
| Hessen | 5.50 | 1.28 | 5.61 |
| Rheinland-Pfalz | 5.84 | 1.52 | 5.68 |
| Schleswig-Holstein | 5.98 | 0.80 | 6.12 |
| Hamburg | 6.11 | NA | 6.11 |
| Niedersachsen | 6.18 | 1.77 | 6.37 |
| Saarland | 6.33 | 1.85 | 5.89 |
| **Sachsen** | **6.47** | **0.88** | **6.27** |
| **Thüringen** | **6.68** | **1.64** | **6.12** |
| **Brandenburg** | **7.06** | **1.63** | **7.19** |
| Nordrhein-Westfalen | 7.36 | 2.33 | 6.94 |
| **Mecklenburg-Vorpommern** | **7.94** | **1.20** | **8.26** |
| **Sachsen-Anhalt** | **8.09** | **1.48** | **7.89** |
| Berlin | 8.47 | NA | 8.47 |
| Bremen | 10.24 | 3.56 | 10.24 |

*Bitte beachten:*
Berlin und Hamburg bestehen aus nur einem Kreis, daher keine SD.

[1] Die ostdeutschen Bundesländer sind grau hinterlegt.

> Was ist hier eine **Beobachtung**? Und was lernen wir aus der Tabelle?

- Süden: Bayern und Baden-Württemberg im Mittel um **4 % oder darunter**, mit geringer Streuung
- Alle ostdeutschen Länder über **6,4 %**
- Aber: NRW (7,4 %) liegt im Ost-Bereich und hat die **höchste Streuung** der Flächenländer (2,33): Ruhrgebiet vs. Münsterland
- Median meist nahe am Mittelwert

# 🔁 Wiedersehen mit Bug Hunt 4 (Teil 1): Bremen

Laut Tabelle hat **Bremen** die höchste Arbeitslosenquote: **10,2 %**. Das Land Bremen besteht aus zwei Kreisen:

```
gesamtdaten |>
  filter(bundesland_name == "Bremen") |>
  select(landkreis_name, total_alo, erw, alo_quote)
```

```
# A tibble: 2 × 4
  landkreis_name total_alo    erw alo_quote
  <chr>              <dbl>  <dbl>     <dbl>
1 Bremen            32077. 383383      7.72
2 Bremerhaven        9039.  61816     12.8
```

**2 Minuten:** Ist 10,2 % die Arbeitslosenquote **des Landes Bremen**? Wie hoch ist sie wirklich? Woher kennen Sie das Problem?

02:00

# 🔁 Bremen: Prüfung

`mean(alo_quote)` ist das Mittel aus Bremen (7,7 %) und Bremerhaven (12,8 %), obwohl Bremen sechsmal so viele Erwerbstätige hat. Die Quote des Landes: **erst summieren, dann teilen.**

```
gesamtdaten |>
  group_by(bundesland_name) |>
  summarise(mittel_kreise = mean(alo_quote),
            quote_land    = sum(total_alo) / sum(erw + total_alo) * 100) |>
  arrange(desc(abs(quote_land - mittel_kreise))) |>
  print(n = 4)
```

```
# A tibble: 16 × 3
  bundesland_name mittel_kreise quote_land
  <chr>                   <dbl>      <dbl>
1 Bremen                  10.2        8.45
2 Hessen                   5.50       5.12
3 Saarland                 6.33       6.67
4 Thüringen                6.68       6.34
# ℹ 12 more rows
```

> ⚠ Beide Zahlen sind richtig gerechnet, sie beantworten nur **verschiedene Fragen**: "Wie geht es dem *durchschnittlichen Landkreis*?" vs. "Wie hoch ist die Quote *im Land*?" Der Fehler ist, die eine zu berechnen und die andere in die Überschrift zu schreiben.

**Faustregel:** Ob das Mittel der Kreise über oder unter der Landesquote liegt, hängt davon ab, ob die **großen** Kreise eine niedrige oder hohe Quote haben. In Bremen hat die große Stadt die niedrigere Quote → das Mittel ist zu hoch.

# ✍️ Jetzt Sie: die Länderquote

Berechnen Sie je Bundesland `quote_land` (gewichtet: Summen, dann teilen) und `mittel_kreise` (ungewichtet), sowie deren Differenz `diff`. Sortieren Sie nach `diff`.

Exercise | Start Over | Show Hint | ▷ Run Code

```
gesamtdaten |>
  group_by(bundesland_name) |>
  summarise(mittel_kreise = ______,
            quote_land    = ______) |>
  mutate(diff = quote_land - mittel_kreise) |>
  arrange(diff) |>
  print(n = 16)
```

04:00

# Ost und West

Die Tabelle legt nahe: Der Unterschied verläuft zwischen Ost und West. Dafür eine neue Variable:

```
gesamtdaten <- gesamtdaten |>
  mutate(ost       = bundesland_name %in% ost_laender,
         ost_name = if_else(ost, "Ostdeutschland", "Westdeutschland"))
```

> 🔮 **Prognose:** Wohin gehört Berlin? Was würden Sie entscheiden, und warum?

Wir ordnen Berlin **Westdeutschland** zu: Ost- und Westberlin sind in den Daten nicht getrennt. Wichtig ist nicht *welche* Entscheidung, sondern dass sie **dokumentiert** ist (Fußnote!).

# Ost und West im Vergleich

```r
ost_west <- gesamtdaten |>
  group_by(ost_name) |>
  summarise(mean = mean(alo_quote), sd = sd(alo_quote),
            min  = min(alo_quote),  p25 = quantile(alo_quote, 0.25),
            median = median(alo_quote), p75 = quantile(alo_quote, 0.75),
            max  = max(alo_quote), n = n())
ost_west |>
  kbl(col.names = c("", "Mittelwert", "SD", "Min.", "P25", "Median", "P75", "Max.", "n"), digits = 2,
      format.args = list(decimal.mark = ",")) |>
  kable_styling(font_size = 16) |>
  add_header_above(c(" " = 1, "Arbeitslosenquote der Landkreise" = 7, " " = 1)) |>
  footnote(general = "Berlin ist Westdeutschland zugeordnet.", general_title = "Bitte beachten: ")
```

| | Arbeitslosenquote der Landkreise | | | | | | |
|---|---|---|---|---|---|---|---|
| | **Mittelwert** | **SD** | **Min.** | **P25** | **Median** | **P75** | **Max.** | **n** |
| Ostdeutschland | 7,13 | 1,55 | 4,17 | 6,03 | 7,02 | 8,00 | 11,61 | 75 |
| Westdeutschland | 5,26 | 2,05 | 1,88 | 3,67 | 4,73 | 6,45 | 14,46 | 325 |

*Bitte beachten:*
Berlin ist Westdeutschland zugeordnet.

**3 Min., zu zweit:** Beschreiben Sie die Tabelle in drei Sätzen, einer davon mit einem Quantil.

03:00

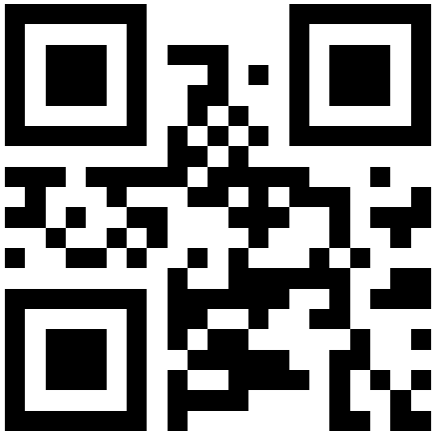
# Ost und West: beschrieben

- Mittelwert im Osten **1,9 Prozentpunkte höher** (7,13 % vs. 5,26 %)
- Streuung im Westen **größer** (SD 2,05 vs. 1,55): Der Westen reicht von München bis Gelsenkirchen
- Westen: Median (4,73 %) **deutlich unter** dem Mittelwert → einige Kreise mit sehr hoher Quote ziehen ihn hoch; Osten: Median ≈ Mittelwert
- **Quantile:** Drei Viertel der ostdeutschen Kreise liegen über 6,03 %, drei Viertel der westdeutschen unter 6,45 %
- Selbst der beste ostdeutsche Kreis (4,17 %, Dahme-Spreewald) liegt unter dem westdeutschen Median

Große Unterschiede zwischen Ost und West, aber auch **innerhalb** des Westens.

Eine Tabelle mit Arbeitslosigkeit, BIP und Schulden je Bundesland finden Sie im Anhang und in der ausformulierten Case-Study.

# Kahoot-Checkpoint 2: Tabellen



**kahoot.it** · PIN am Beamer

## 6 Fragen, 5 Minuten

- `group_by()` + `summarise()`: Was ist danach eine Beobachtung?
- Welche `kableExtra`-Funktion macht was?
- Bug Hunt 7: feste Zeilennummern
- Bremen: Mittel der Kreise vs. Quote des Landes
- Quantile lesen
- Mittelwert vs. Median im Westen

Kahoot öffnen →

05:00

# Ende von Sitzung 1

**Heute:** Daten beschreiben und prüfen: `skimr`, Tabellen, Kennzahlen je Gruppe.

**Bis zur nächsten Sitzung:**

- Abschnitt *Deskriptive Analysen* der ausformulierten Case-Study lesen
- Anhang “Zum Selbststudium” am Ende dieser Folien: Stadtstaaten-Join reparieren

Nächstes Mal: Grafiken, Karten und Zusammenhänge. Wir starten mit Kahoot-Checkpoint 2 als Recap.

# Sitzung 2

# Recap: Kahoot-Checkpoint 2

**Dieselben 6 Fragen wie am Ende der letzten Sitzung.**

Tipp: Folien jetzt auf dem Laptop öffnen, damit webR im Hintergrund lädt.

Kahoot öffnen →

**kahoot.it** · PIN am Beamer

05:00

# Schätzfrage zum Einstieg

**30 Sekunden, notieren:** Das mittlere BIP pro Kopf der ostdeutschen Landkreise lag 2024 bei wie viel Prozent des westdeutschen?

**(a)** 55 % **(b)** 65 % **(c)** 75 % **(d)** 85 %

Und: Ist der Abstand seit 2000 kleiner oder größer geworden?

# Grafiken

Grundlagen ✔ → Überblick ✔ → Tabellen ✔ → **Grafiken** → Karten → Zusammenhänge

**Nach diesem Abschnitt können Sie …**

- eine Verteilung zeigen, ohne Daten zu verstecken (Punkte + Boxplot, Histogramm),
- eine logarithmische Achse richtig lesen,
- eine Wachstumsrate richtig berechnen und prüfen,
- eine Grafik interaktiv machen (`plotly`).

# Warum Grafiken?

Das Auge verarbeitet Informationen in einer Grafik deutlich schneller und intuitiver als in einer Tabelle.

**Daten:** Arbeitslosenquote 2024 aller 400 Landkreise.

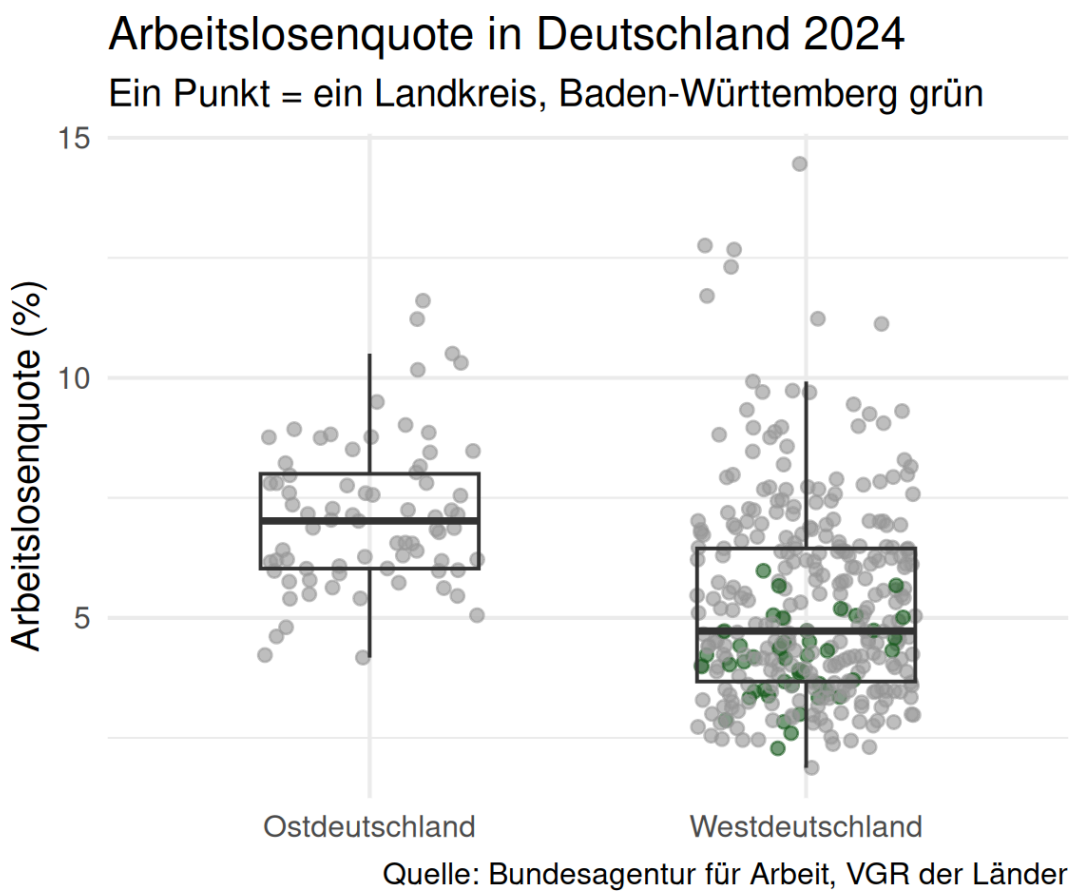
Die Grafik soll

- **alle Daten zeigen:** jeder Landkreis ein Punkt,
- einen **Boxplot** darüberlegen, um Ost und West zu vergleichen,
- **Baden-Württemberg** hervorheben: Wo stehen wir?

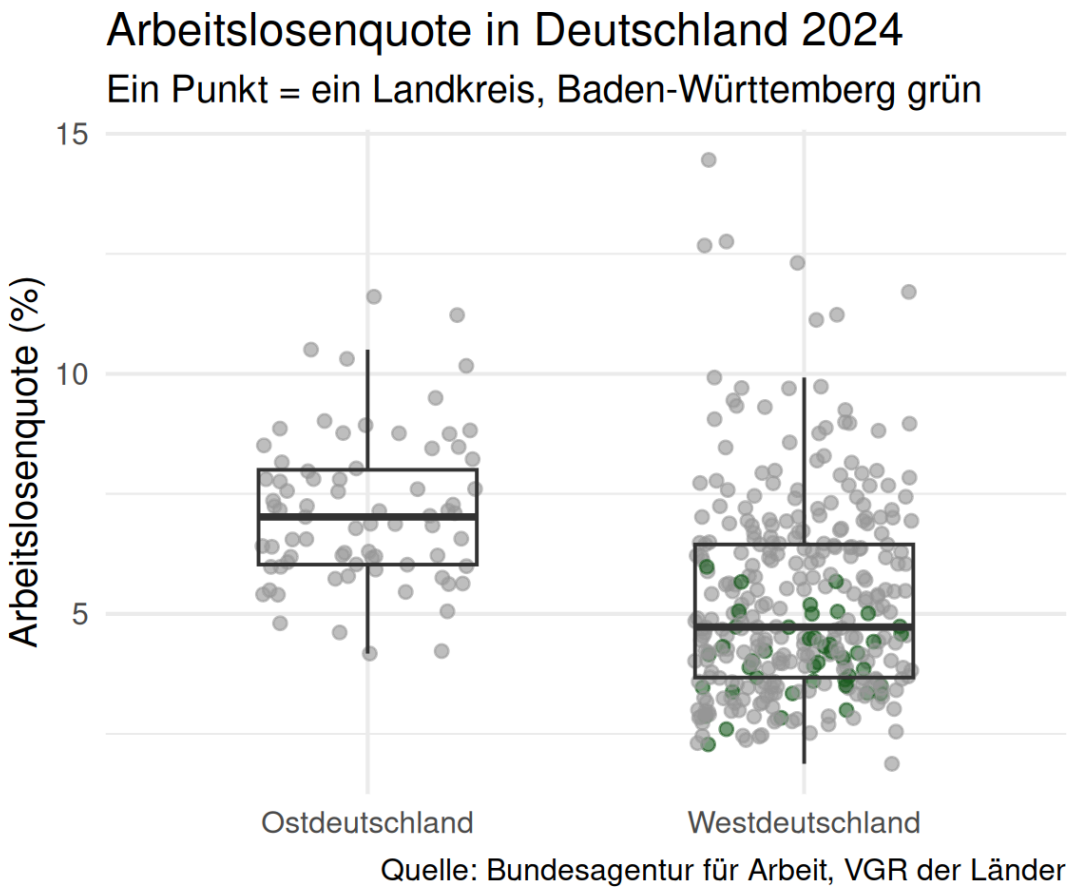
# Alle Daten zeigen

```r
gesamtdaten |>
  mutate(bw = bundesland_name == "Baden-Württemberg") |>
  ggplot(aes(x = ost_name, y = alo_quote)) +
  geom_jitter(aes(colour = bw), width = 0.25, height = 0, alpha = 0.6) +
  geom_boxplot(alpha = 0, outlier.shape = NA, width = 0.5) +
  scale_colour_manual(values = c("grey60", "#1b5e20"), guide = "none") +
  labs(title = "Arbeitslosenquote in Deutschland 2024",
       subtitle = "Ein Punkt = ein Landkreis, Baden-Württemberg grün",
       x = NULL, y = "Arbeitslosenquote (%)",
       caption = "Quelle: Bundesagentur für Arbeit, VGR der Länder") +
  theme_minimal(base_size = 15)
```

🔮 Wozu `height = 0` und `outlier.shape = NA`? Was passiert ohne?



# Beschreiben Sie das Schaubild




**3 Min., zu zweit:** Beschreiben Sie das Schaubild in drei Sätzen. Wo liegt BW?

- **77 %** der Kreise in BW liegen unter dem West-Median
- Median West 4,7 % vs. Ost 7,0 %
- Selbst das 75 %-Quantil West (6,4 %) liegt unter dem Ost-Median
- Fast alle Kreise unter 10 % (Spanien: rund 11 %)

03:00

# BIP pro Kopf: Unterschiede seit wann?

Gibt es auch beim **BIP pro Kopf** regionale Unterschiede? Und **war das schon immer so**?

- Bestehen die Unterschiede schon länger?
- Werden sie größer oder kleiner?

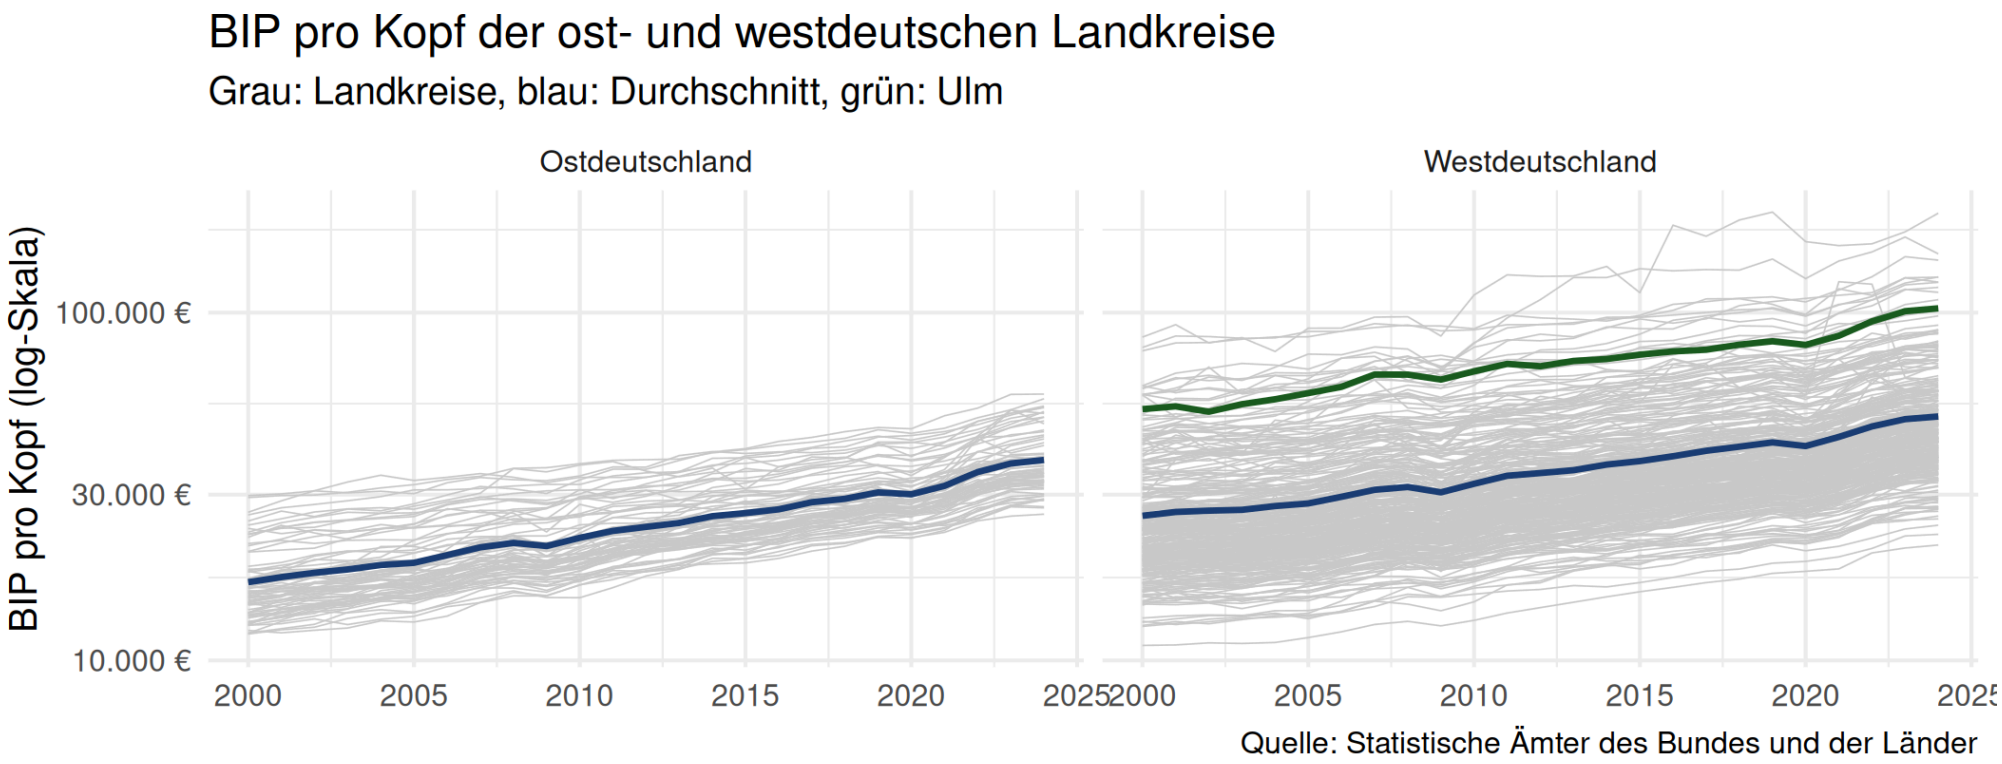
Ein hohes BIP pro Kopf kann bedeuten, dass

- viele Personen im Landkreis **erwerbstätig** sind, oder
- die Erwerbstätigen in Branchen mit **hoher Produktivität** arbeiten.

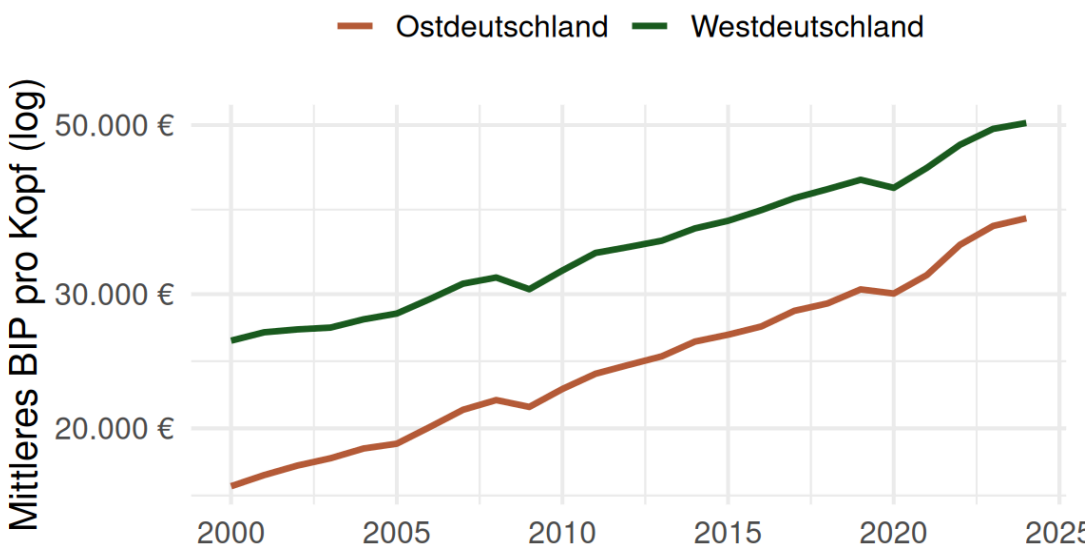
> Trifft der erste Punkt zu, sollte ein hohes BIP pro Kopf mit **niedriger Arbeitslosigkeit** einhergehen. Und wo kann es noch herkommen? (Tipp: Bug Hunt 6)

# BIP pro Kopf seit 2000

Grafik | Code



# 🔮 Holt der Osten auf?




```
# A tibble: 3 × 3
   Jahr abstand_eur ost_in_prozent_west
  <dbl>       <dbl>               <dbl>
1  2000       9272.                64.4
2  2010       9694.                69.9
3  2024      12587.                75.0
```

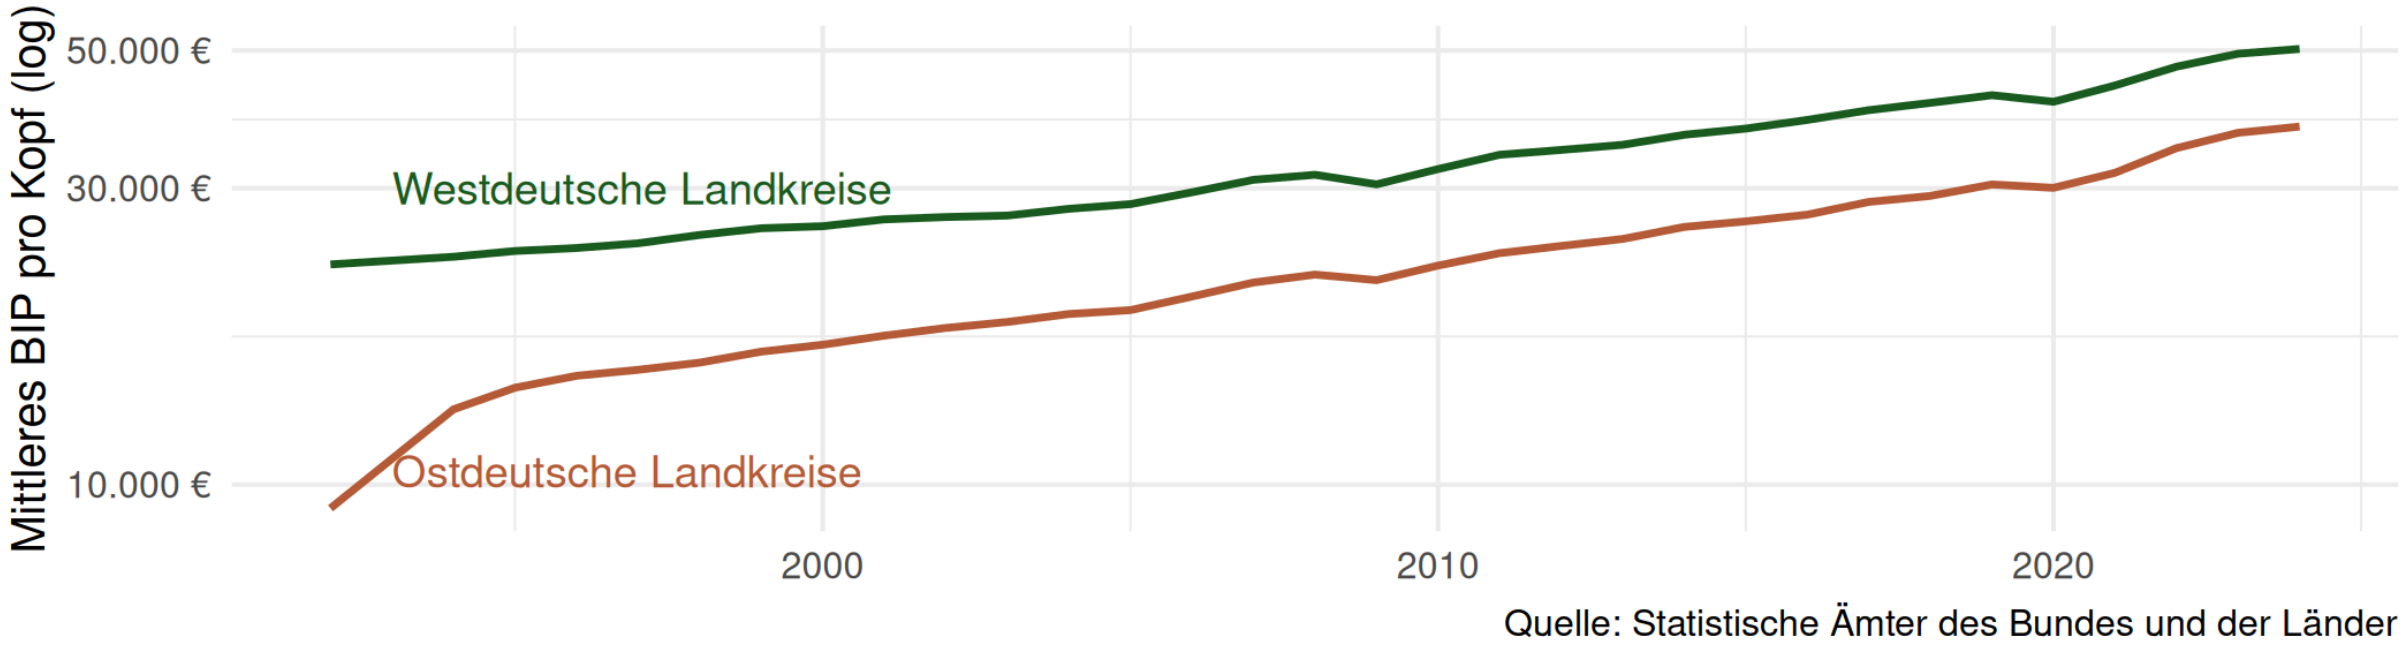
> **Handzeichen:** Die Linien laufen fast parallel. Holt der Osten seit 2000 auf?
>
> **(a)** ja **(b)** nein **(c)** der Abstand wird größer

Alle drei Antworten sind vertretbar:

- **Absolut** wächst der Abstand in Euro
- **Relativ** holt der Osten auf, aber langsam
- **Log-Skala:** "parallel" heißt gleicher *relativer* Abstand

Schätzfrage aufgelöst: **(c) 75 %**

# Der lange Blick: ab 1992




- Starke **Anpassung in den 1990er Jahren**, danach deutlich langsamer
- **Vorsicht:** Bis 1999 fehlen ganz Niedersachsen und Mecklenburg-Vorpommern, 1992 zusätzlich Sachsen und das Saarland (für 1993 gibt es keine Daten). Die Mittelwerte beziehen sich also nicht jedes Jahr auf dieselben Kreise

# Wachstumsraten

Wir haben ein **Panel** und können das **Wachstum** des BIP pro Kopf für jeden Landkreis und jedes Jahr berechnen.

> **Lässt sich ein Aufholprozess auch an den Wachstumsraten ablesen? Was müsste dann gelten?**

Wachstumsrate von Jahr $t-1$ auf Jahr $t$:

$$g_t = \frac{x_t - x_{t-1}}{x_{t-1}} \times 100$$

# 🐛 Bug Hunt 8: Die Wachstumsrate

Der Code aus der Case-Study des letzten Jahres:

```
1 bip_wachstum <- bip_zeitreihe_namen |>
2   group_by(Regionalschluessel) |>
3   arrange(Regionalschluessel, Jahr) |>
4   mutate(wachstum = 100 * (bip_pro_kopf - lag(bip_pro_kopf)) / bip_pro_kopf) |>
5   ungroup()
```

**2 Minuten:** Vergleichen Sie Zeile 4 mit der Formel. Rechnen Sie im Kopf nach: Ein Landkreis **verdoppelt** sein BIP pro Kopf von 100 auf 200. Was gibt der Code aus?

02:00

# Bug Hunt 8: Prüfung

Ein Test mit Zahlen, deren Ergebnis wir kennen:

```
tibble(vorjahr = c(100, 100), jetzt = c(200, 50)) |>
  mutate(falsch  = 100 * (jetzt - vorjahr) / jetzt,
         richtig = 100 * (jetzt - vorjahr) / vorjahr)
```

```
# A tibble: 2 × 4
  vorjahr jetzt falsch richtig
    <dbl> <dbl>  <dbl>   <dbl>
1     100   200     50     100
2     100    50   -100     -50
```

In unseren Daten: **Mainz** (BioNTech) 2021 und 2023

```
bip_wachstum |>
  filter(landkreis_name == "Mainz", Jahr %in% 2020:2023
  select(Jahr, bip_pro_kopf, falsch, wachstum)
```

```
# A tibble: 4 × 4
   Jahr bip_pro_kopf falsch wachstum
  <dbl>        <dbl>  <dbl>    <dbl>
1  2020       57939.   1.18     1.19
2  2021      122763.  52.8    112.
3  2022      120782.  -1.64    -1.61
4  2023       65041. -85.7    -46.2
```

Geteilt wird durch das **aktuelle** Jahr statt durch das **Vorjahr**. Kleine Raten ändern sich kaum, **große werden stark verzerrt**: Verdopplung → +50 %, Halbierung → −100 %.

# ✍️ Jetzt Sie: Bug Hunt 8 reparieren

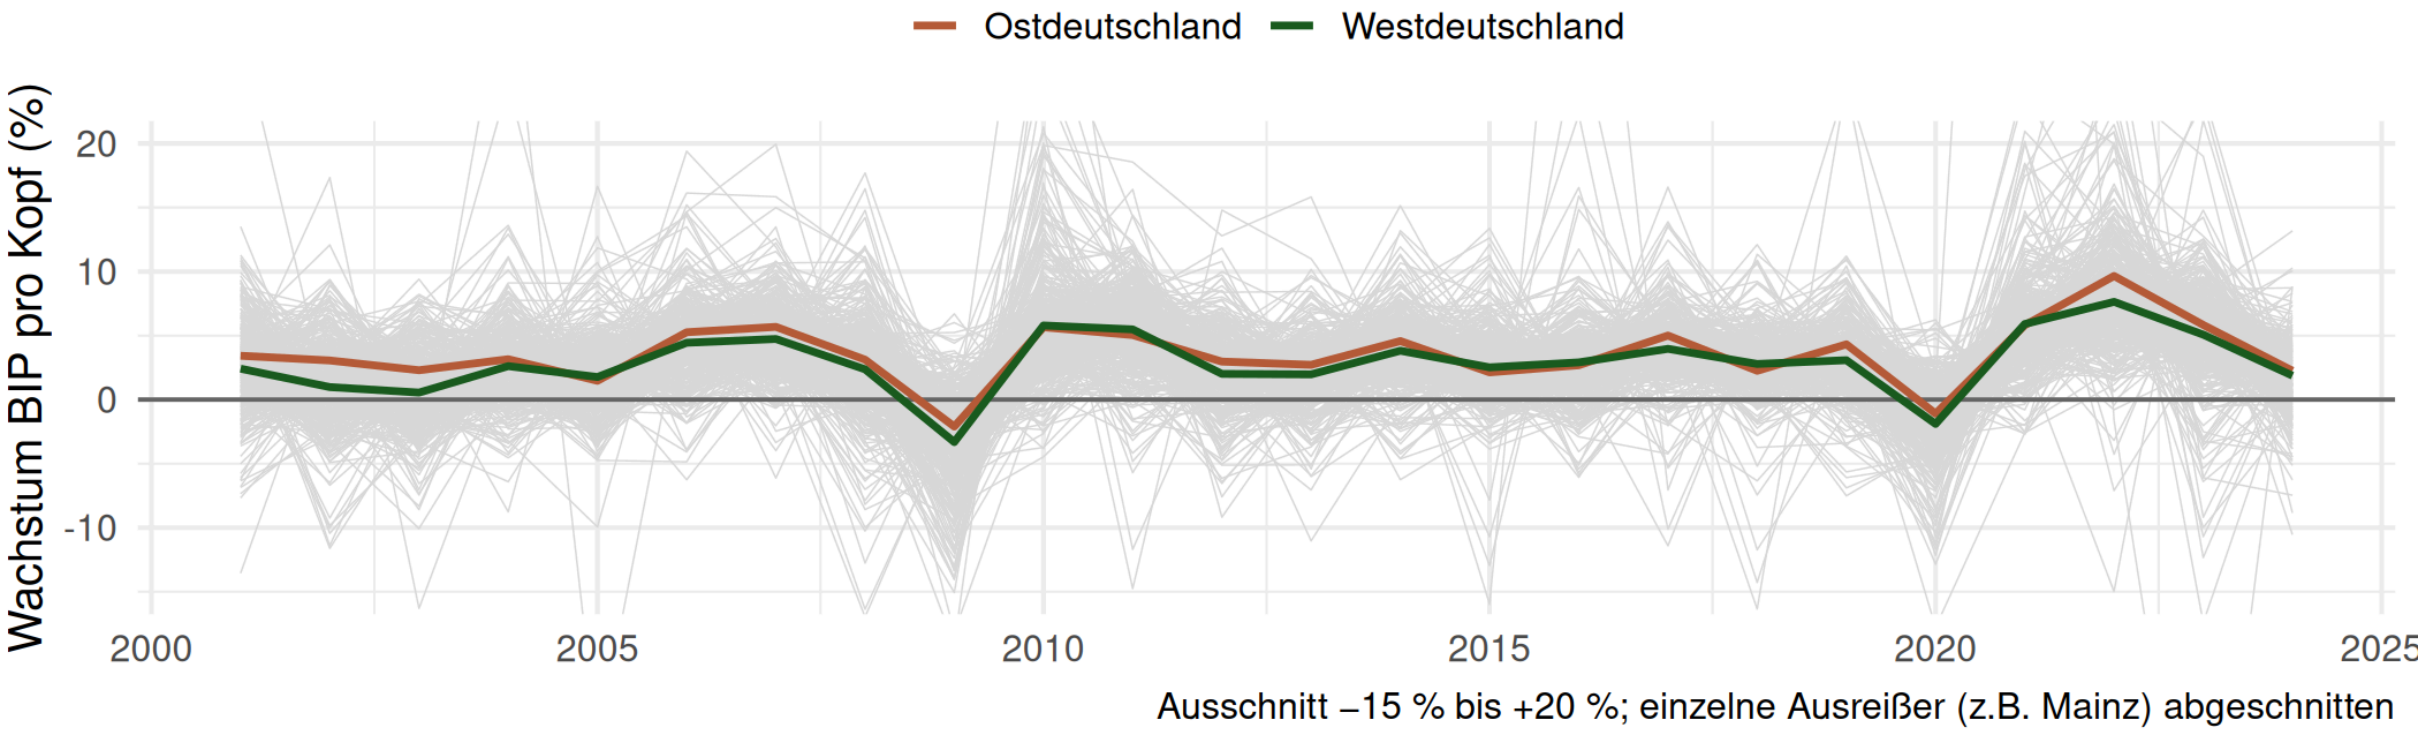
`bip_lk` enthält das BIP pro Kopf aller Landkreise 2015–2024. Berechnen Sie `wachstum` richtig und zeigen Sie die **fünf höchsten** Wachstumsraten.

Exercise | Start Over | Show Hint | ▷ Run Code

```
1 bip_lk |>
2   group_by(Regionalschluessel) |>
3   arrange(Jahr, .by_group = TRUE) |>
4   mutate(wachstum = 100 * (bip_pro_kopf - lag(bip_pro_kopf)) / bip_pro_kopf) |>
5   ungroup() |>
6   slice_max(wachstum, n = 5)
```

04:00

# Wachstumsraten: Ost und West




Was sehen Sie? Und warum wachsen **2022** fast alle Landkreise, im Mittel um rund 8 %?

# Wachstumsraten: beschrieben

**Beschreibung**

- Im Mittel sehr ähnliche Wachstumsraten, Ost meist leicht darüber
- Einbrüche in der **Finanzkrise 2009** und in **Corona 2020** in den meisten Landkreisen
- Einzelne Landkreise mit extremen Raten: ein großes Unternehmen reicht (Mainz/BioNTech 2021, Wolfsburg/VW 2016)

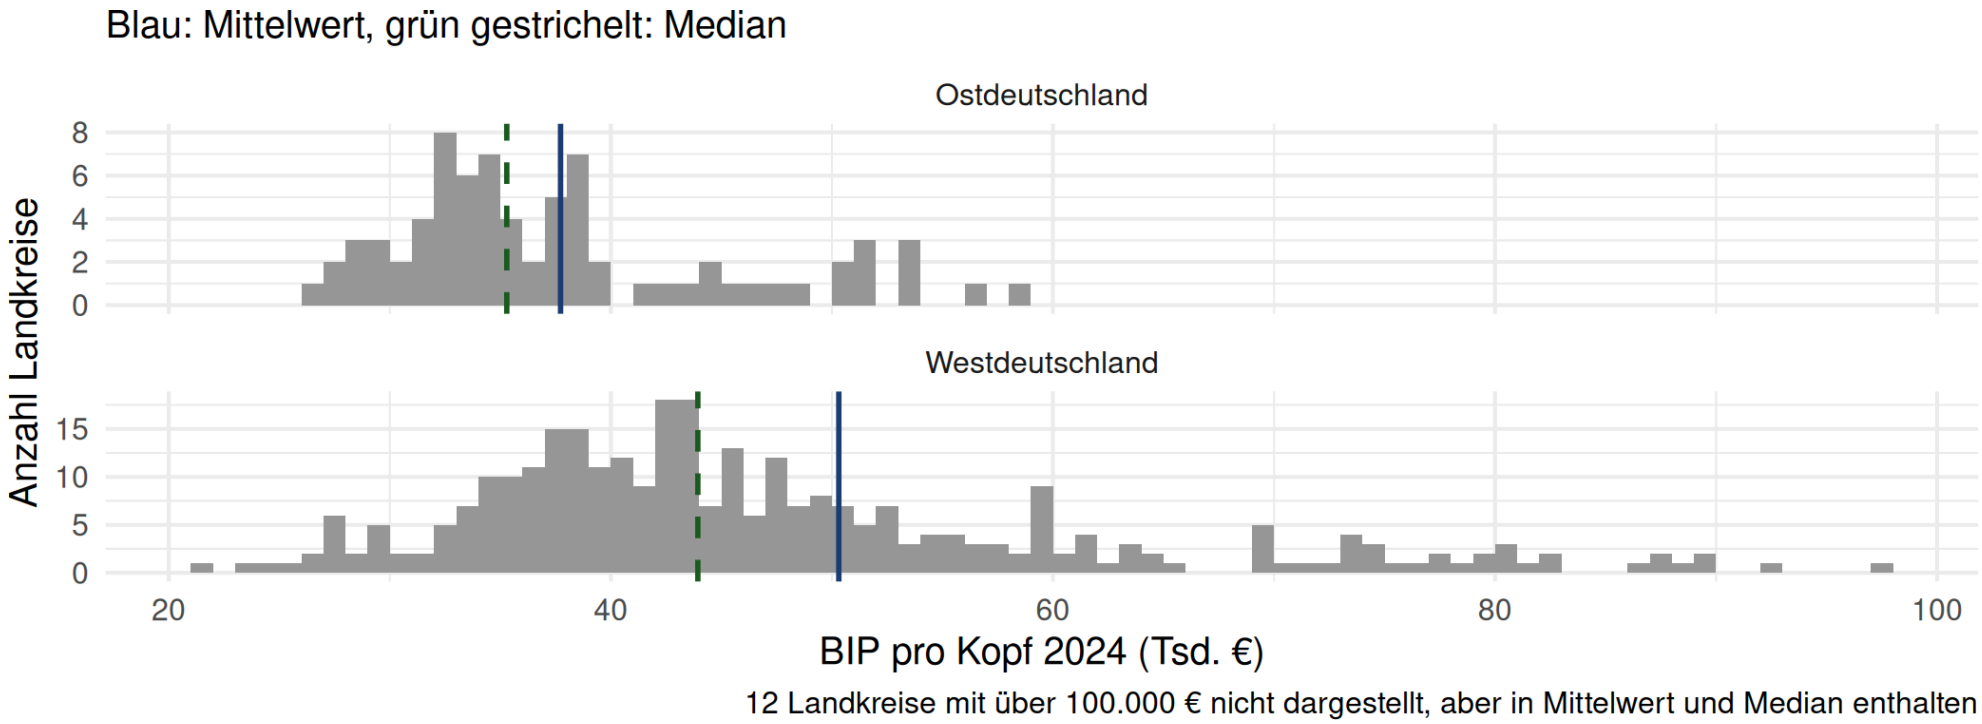
**Interpretation**

- Leicht höhere Raten im Osten passen zum langsamen relativen Aufholen
- Für eine schnelle Angleichung sind die Unterschiede aber zu klein
- Das BIP ist **nominal**: 2022 ist vor allem Inflation, kein Boom

Kein schneller Aufholprozess seit 2000, aber auch kein Stillstand.

# Die Verteilung 2024: Histogramm

Grafik | Code



# Die Verteilung 2024: beschrieben

- Ost: Mittelwert 37.724 €, Median 35.292 € → **schmaler**, Mittelwert und Median näher beieinander
- West: Mittelwert 50.312 €, Median 43.935 € → **lange rechte Flanke**
- Es gibt westdeutsche Kreise mit niedrigerem BIP pro Kopf als viele ostdeutsche, aber der Großteil liegt rechts davon

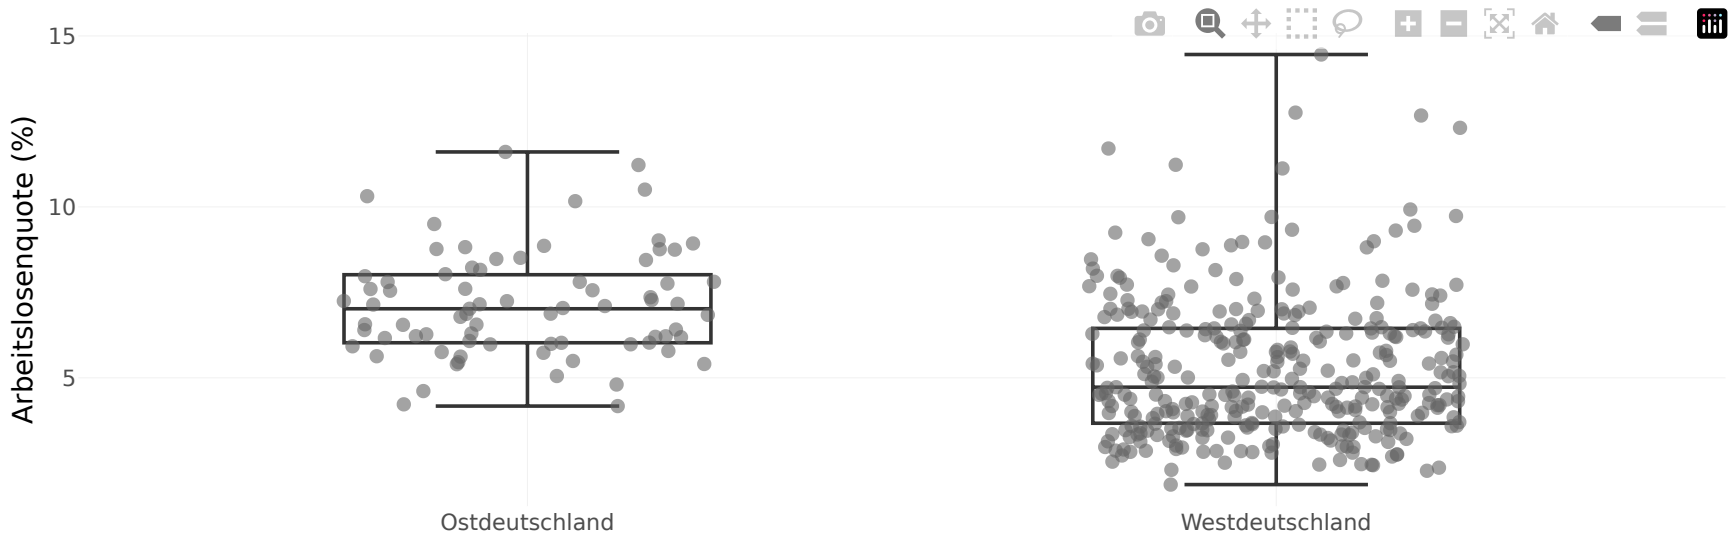
> **Die y-Achse zeigt die Anzahl. Warum ist das beim Vergleich Ost (75 Kreise) und West (325 Kreise) problematisch? Was wäre die Alternative?**

Die Alternative ist eine **Kerndichte** (`geom_density()`), ein geglättetes Histogramm mit Fläche 1. Mehr dazu und weitere Grafiktypen (z.B. Small Multiples) finden Sie in der ausformulierten Case-Study, bei Data to Viz und in der R Graph Gallery.

# Interaktiv mit `plotly`

Wer ist der Ausreißer? Mit der Maus über einen Punkt fahren:

```r
p_interaktiv <- gesamtdaten |>
  ggplot(aes(x = ost_name, y = alo_quote)) +
  geom_jitter(aes(text = paste0(landkreis_name, " (", bundesland_name, "): ", round(alo_quote, 1), " %")),
              width = 0.25, height = 0, alpha = 0.6, colour = "grey40") +
  geom_boxplot(alpha = 0, outlier.shape = NA, width = 0.5) +
  labs(x = NULL, y = "Arbeitslosenquote (%)") + theme_minimal()
ggplotly(p_interaktiv, tooltip = "text")
```




Funktioniert in HTML (Folien, Case-Study, Quarto-Bericht), **nicht im PDF**. Für den Projektbericht: statische Grafik zusätzlich bereithalten.

# Karten

Grundlagen ✔ → Überblick ✔ → Tabellen ✔ → Grafiken ✔ → **Karten** → Zusammenhänge

**Nach diesem Abschnitt können Sie …**

- eine Karte mit `geom_sf()` lesen und anpassen,
- eine stetige Variable mit `cut()` lückenlos in Klassen einteilen,
- Legende und Farbskala einer Karte kritisch prüfen.

# Verschuldung und Arbeitslosigkeit

**Warum könnte die Verschuldung der öffentlichen Haushalte mit einer hohen Arbeitslosenquote zusammenhängen?**

- Strukturschwache Regionen: weniger Unternehmen → weniger **Gewerbesteuer**
- Gleichzeitig höhere **Sozialausgaben** (Kosten der Unterkunft für SGB-II-Leistungsbeziehende tragen die Kommunen)
- Folge: Kredite statt Investitionen → Region wird für Unternehmen noch unattraktiver

Ursache oder Folge? Beides ist plausibel. Mit deskriptiver Statistik können wir das **nicht** trennen.

# Karten in R

Die Geodaten (`landkreise`, `bundesland`) aus Teil 1 sind `sf`-Objekte: eine Tabelle mit einer Spalte `geometry`.

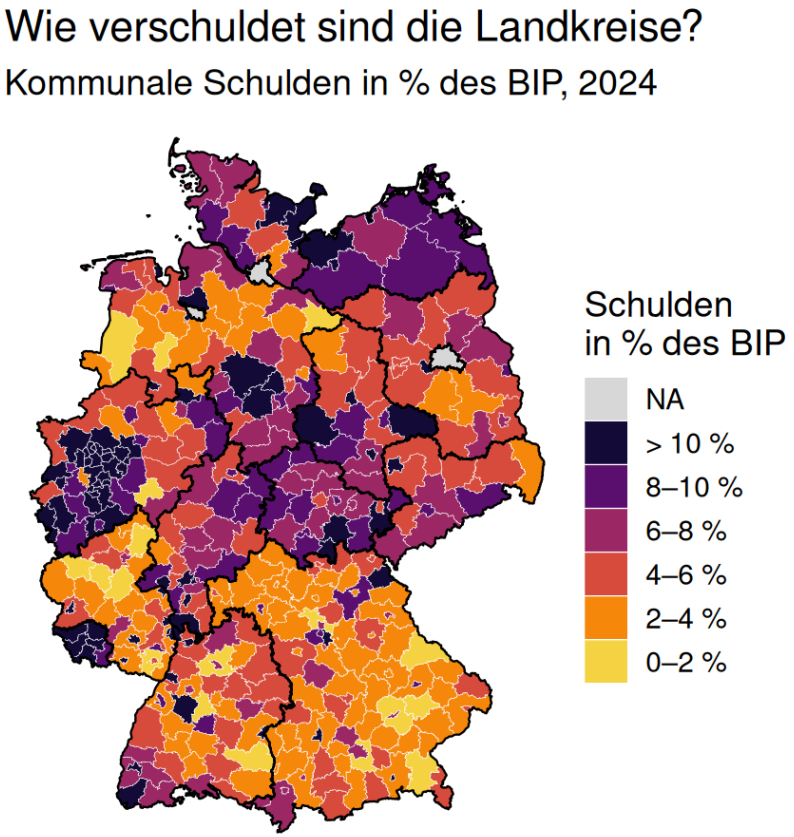
```
karten_daten <- left_join(landkreise, gesamtdaten, by = "Regionalschluessel") |>
  mutate(anteil_schulden = Schulden_gesamt / bip * 100,
         schulden_klasse = cut(anteil_schulden, breaks = c(0, 2, 4, 6, 8, 10, Inf),
                               labels = c("0–2 %", "2–4 %", "4–6 %", "6–8 %", "8–10 %", "> 10 %")))
```

> 🔮 Warum steht `landkreise` **zuerst** im `left_join()` und nicht `gesamtdaten`?

Das Ergebnis übernimmt die Klasse des **linken** Datensatzes. Nur wenn links ein `sf`-Objekt steht, ist das Ergebnis wieder eine Karte.

# Schulden im Verhältnis zum BIP

Karte | Code




**3 Minuten, zu zweit:** Beschreiben und interpretieren Sie die Karte. Welche Regionen fallen auf?

Grau: Stadtstaaten. Ihre Schulden sind Landesschulden und nicht in der Gemeindestatistik.

03:00

# Schulden: beschrieben

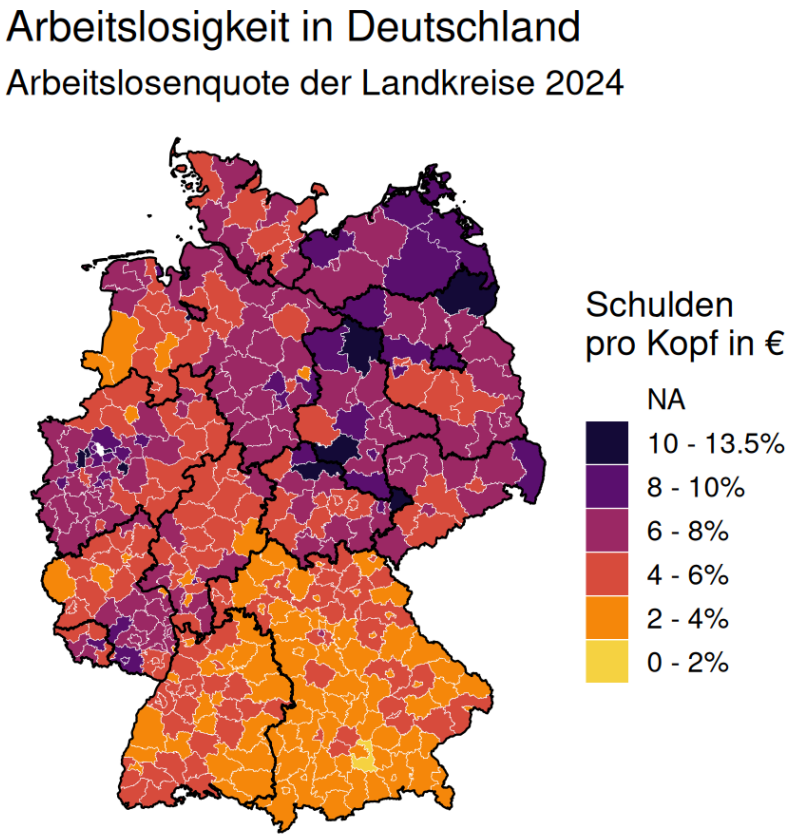
## Beschreibung

- **Niedrig** verschuldet (Landesebene, Schulden/BIP): Bayern, Baden-Württemberg, Rheinland-Pfalz, Brandenburg
- **Hoch** verschuldet: Saarland, Mecklenburg-Vorpommern, Nordrhein-Westfalen, Sachsen-Anhalt
- Kein klares Ost-West-Muster: Brandenburg gering, Sachsen im Mittelfeld, Sachsen-Anhalt und Mecklenburg-Vorpommern hoch

## Interpretation

- **Ruhrgebiet und Saarland:** Strukturwandel seit dem Ende von Kohle und Stahl, hohe Sozialausgaben, lange Phase von Kassenkrediten
- **Achtung, Pendler:** Das BIP wird am Arbeitsort gemessen. Umlandkreise mit vielen Auspendler:innen haben ein kleines BIP und wirken dadurch **verschuldeter**, als sie sind

# Bug Hunt 9: Die Arbeitslosen-Karte




Die Karte aus den Folien des letzten Jahres. Der Code läuft ohne Fehler und ohne Warnung.

> **2 Minuten, zu zweit:** In dieser Karte stecken **zwei** stille Fehler. Lesen Sie die Legende Wort für Wort. Und: Wo ist der Kreis mit der höchsten Arbeitslosenquote?

02:00

# Bug Hunt 9: Prüfung

```
mutate(alo_quote_lk = as.factor(case_when(
    alo_quote <= 2 ~ "0 - 2%",
    ...
    alo_quote > 8 & alo_quote <= 10 ~ "8 - 10%",
    alo_quote > 10 & alo_quote <= 13.5 ~ "10 - 13.5%")))
```

```
karten_daten_alt |>
  sf::st_drop_geometry() |>
  filter(is.na(alo_quote_lk)) |>
  select(landkreis_name, alo_quote)
```

```
  landkreis_name alo_quote
1  Gelsenkirchen  14.45649
```

1. **Legende:** “Schulden pro Kopf in €” auf einer Karte zur Arbeitslosenquote. Copy & Paste von der Schuldenkarte.
2. **Lücke:** `case_when()` ohne Fall für Werte über 13,5 % → `NA`. Ausgerechnet der **Extremwert** verschwindet.

Nach jeder Klasseneinteilung: `count(klasse)`. Eine `NA`-Klasse, die es nicht geben sollte, fällt sofort auf.

# ✍️ Jetzt Sie: Klassen ohne Lücke

Ersetzen Sie `case_when()` durch `cut()`, sodass **jeder** Landkreis eine Klasse bekommt, auch wenn nächstes Jahr ein Kreis über 15 % liegt. Die letzte Zeile soll die Klassen zählen.

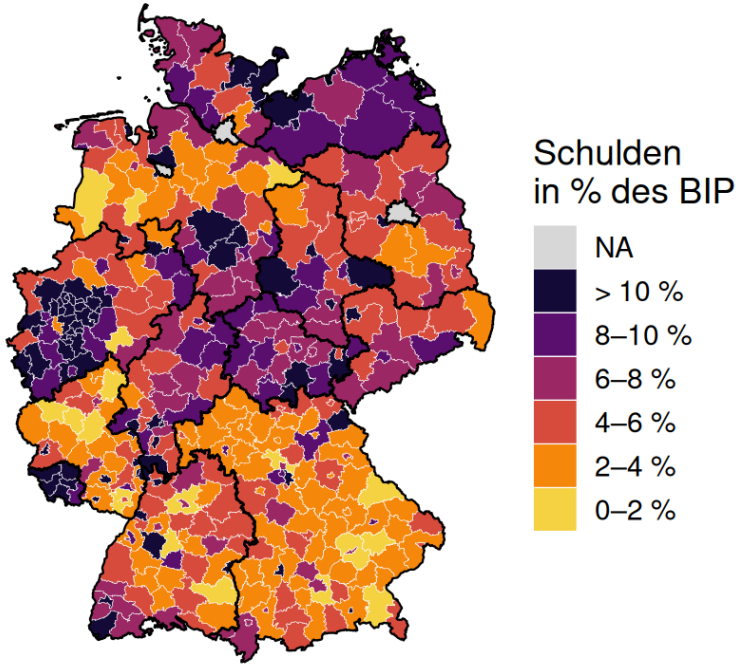
Exercise | Start Over | Show Hint | ▷ Run Code

```
gesamtdaten |>
  mutate(klasse = case_when(alo_quote <= 2 ~ "0-2",
                            alo_quote <= 4 ~ "2-4",
                            alo_quote <= 6 ~ "4-6",
                            alo_quote <= 8 ~ "6-8",
                            alo_quote <= 10 ~ "8-10",
                            alo_quote <= 13.5 ~ "10-13.5")) |>
  count(klasse)
```

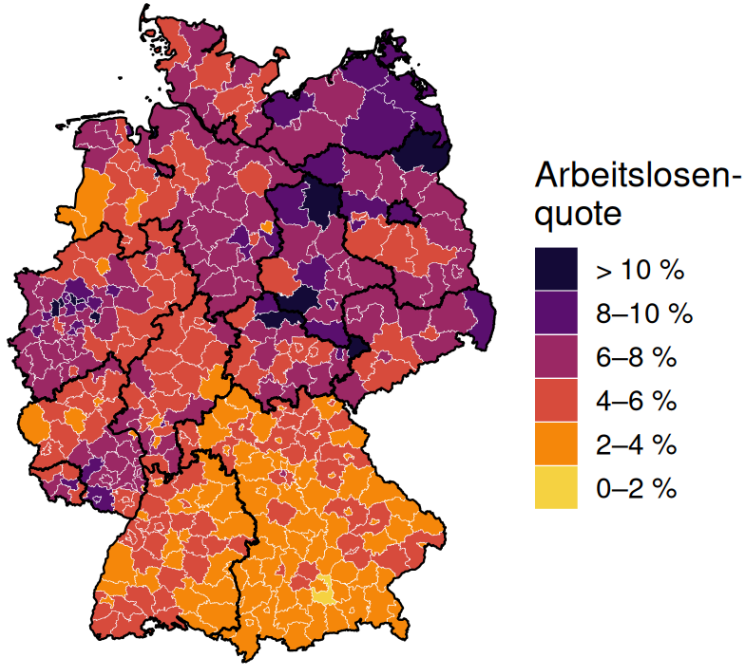
04:00

# Schulden und Arbeitslosigkeit im Vergleich

Schulden in % des BIP




Arbeitslosenquote




Hängen Verschuldung und Arbeitslosigkeit zusammen? Wie sicher sind Sie sich, nur mit dem Auge?

# Was die Karten zeigen und was nicht

- **Ost-West** ist bei der Arbeitslosigkeit deutlich sichtbar, bei den Schulden kaum
- **Im Westen** fallen beide Karten zusammen: Ruhrgebiet und Saarland sind hoch verschuldet **und** haben hohe Arbeitslosigkeit
- Verschuldung könnte ein erklärender Faktor sein, aber “fällt zusammen” ist keine Zahl

Das Auge ist schlecht darin, zwei Farbskalen zu vergleichen. Für Zusammenhänge brauchen wir **Streudiagramm und Korrelation** → nächster Abschnitt.

**Gute Karten:** kontrastreiche, farbenblind-taugliche Palette (`viridis`), wenige Klassen, Grenzen per `cut()` lückenlos, fehlende Werte erklärt, Legende **gelesen**.

# Zusammenhänge

Grundlagen ✔ → Überblick ✔ → Tabellen ✔ → Grafiken ✔ → Karten ✔ → **Zusammenhänge**

**Nach diesem Abschnitt können Sie …**

- einen Korrelationskoeffizienten aus einem Streudiagramm grob schätzen,
- Korrelationen in R berechnen, auch getrennt nach Gruppen,
- erklären, was eine Korrelation **nicht** aussagt.

# Die Korrelation

**Bisher:** univariat, eine Variable. **Jetzt:** bivariat, der Zusammenhang zweier Variablen.

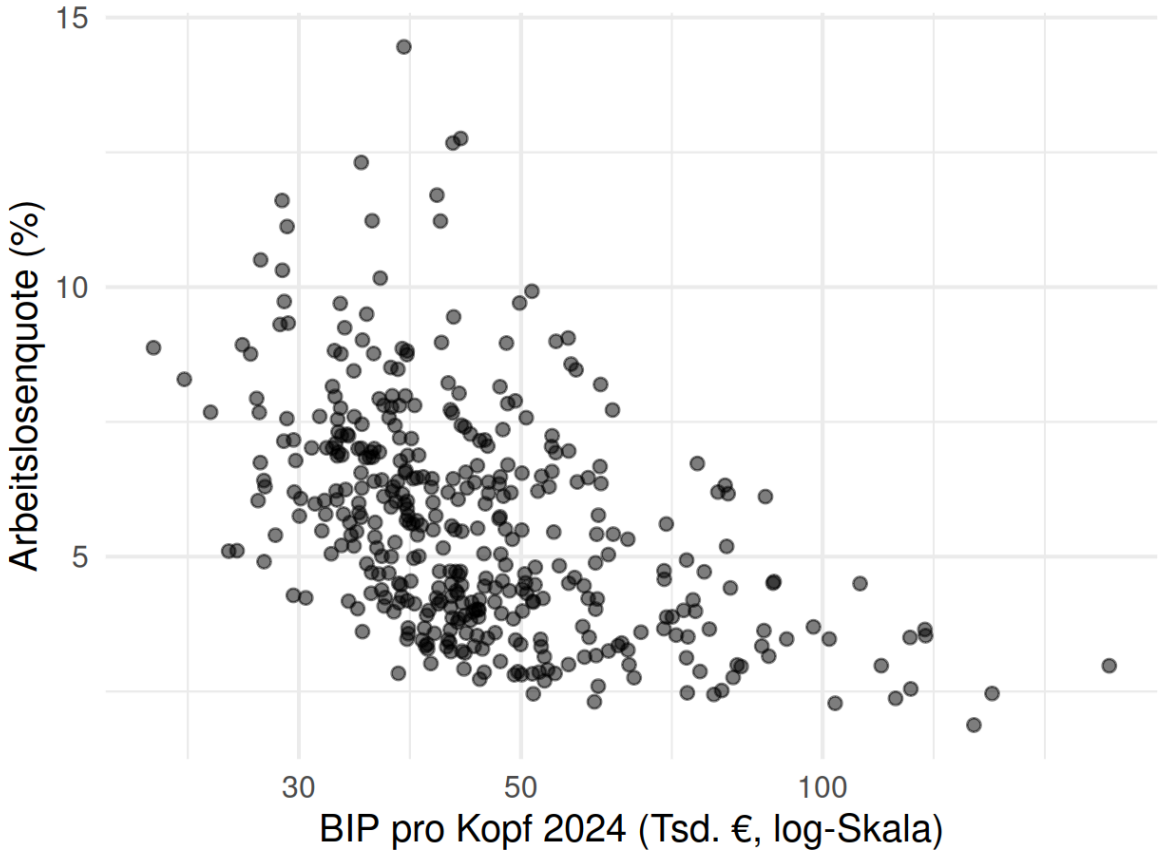
$$r = \frac{1}{n} \sum_{i=1}^{n} \left( \frac{x_i - \mu_x}{\sigma_x} \right) \left( \frac{y_i - \mu_y}{\sigma_y} \right)$$

mit den Mittelwerten $\mu_x$, $\mu_y$ und den Standardabweichungen $\sigma_x$, $\sigma_y$. **r sagt, wie eng die Punkte um eine Gerade liegen, nicht wie steil sie ist.**

| $\lvert r \rvert$ | Zusammenhang (Faustregel) |
|---|---|
| 0,1 – 0,3 | schwach |
| 0,3 – 0,5 | mittel |
| 0,5 – 0,8 | stark |
| > 0,8 | sehr stark |

> Was bedeutet das Produkt in der Summe, wenn ein Landkreis bei $x$ **und** $y$ über dem Mittelwert liegt? Und wenn nur bei einem?

# 🔮 Schätzen Sie r




**Handzeichen:** Wie groß ist die Korrelation?

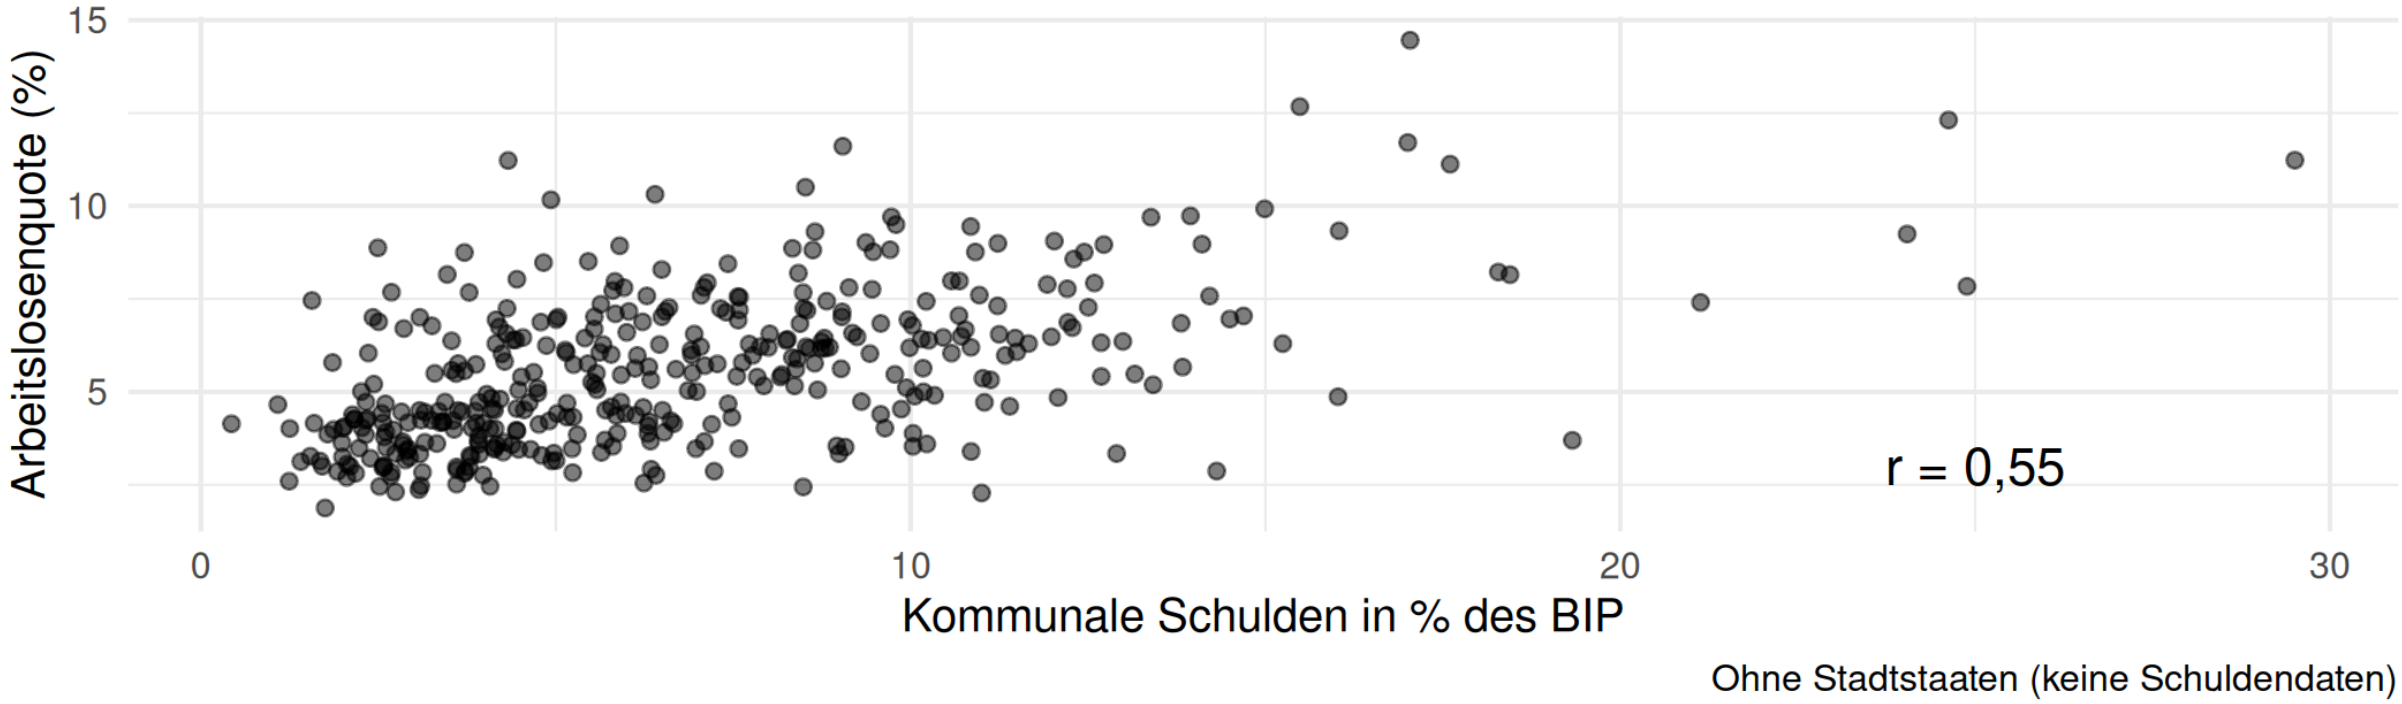
**(a)** −0,9 **(b)** −0,5 **(c)** 0 **(d)** +0,5

```
1 cor(log(gesamtdaten$bip_pro_kopf), gesamtda
```

```
[1] -0.4701483
```

**Mittel negativ:** Wo das BIP pro Kopf hoch ist, ist die Arbeitslosigkeit eher niedrig. Aber mit viel Streuung.

# Arbeitslosigkeit und Verschuldung




Deutlich **positiver** Zusammenhang: Landkreise mit hohen Schulden im Verhältnis zum BIP haben tendenziell eine höhere Arbeitslosenquote.

`annotate()` statt `geom_text(aes(...))`: Ein fester Text wird so **einmal** gezeichnet und nicht 400-mal übereinander.

# ✍️ Jetzt Sie: Welche Schulden-Kennzahl?

Berechnen Sie die Korrelation der Arbeitslosenquote mit **drei** Kennzahlen: Schulden in % des BIP, Schulden pro Kopf, BIP pro Kopf. Ergebnis als **eine** Zeile mit drei Spalten.

Exercise | Start Over | Show Hint | ▷ Run Code

```
gesamtdaten |>
  summarise(r_anteil   = cor(alo_quote, anteil_schulden, use = "complete.obs"),
            r_pro_kopf = ______,
            r_bip      = ______)
```

**Zusatz:** Berechnen Sie `r_anteil` getrennt für Ost und West (`group_by(ost_name)` vor `summarise()`).

04:00

# Die Wahl der Kennzahl entscheidet mit

```r
gesamtdaten |>
  summarise(r_anteil   = r_c(alo_quote, anteil_schulden),
            r_pro_kopf = r_c(alo_quote, Schulden_pro_kopf_lk),
            r_bip      = r_c(alo_quote, bip_pro_kopf))
```

```
# A tibble: 1 × 3
  r_anteil r_pro_kopf  r_bip
     <dbl>      <dbl>  <dbl>
1    0.554      0.195 -0.426
```

> Pro Kopf ist der Zusammenhang **schwach**, in % des BIP **stark**. Woran liegt das? Wer hat die höchsten Schulden pro Kopf?

# Wer hat die höchsten Schulden pro Kopf?

```r
gesamtdaten |>
  slice_max(Schulden_pro_kopf_lk, n = 4) |>
  select(landkreis_name, Schulden_pro_kopf_lk, bip_pro_kopf, anteil_schulden, alo_quote)
```

```
# A tibble: 4 × 5
  landkreis_name      Schulden_pro_kopf_lk bip_pro_kopf anteil_schulden alo_quote
  <chr>                              <dbl>        <dbl>           <dbl>     <dbl>
1 Darmstadt                         18911.       97917.            19.3      3.70
2 Frankfurt am Main                 12707.      126718.            10.0      3.53
3 Mülheim an der Ruhr               12065.       48484.            24.9      7.84
4 Ulm                               11334.      102934.            11.0      2.28
```

- Überwiegend **reiche Städte mit niedriger Arbeitslosigkeit** (Darmstadt, Frankfurt, Ulm!). Sie drücken die Korrelation **pro Kopf**.
- Auch gemessen am BIP sind sie überdurchschnittlich verschuldet. Aber das Teilen durch das BIP schiebt vor allem **strukturschwache Kreise mit kleinem BIP** nach oben (Mülheim, Oberhausen, Herne), und die haben hohe Arbeitslosigkeit.

Beide Kennzahlen sind legitim. Aber wer nur eine zeigt, sollte begründen, warum diese.

# 🐛 Bug Hunt 10: Die KI-Interpretation

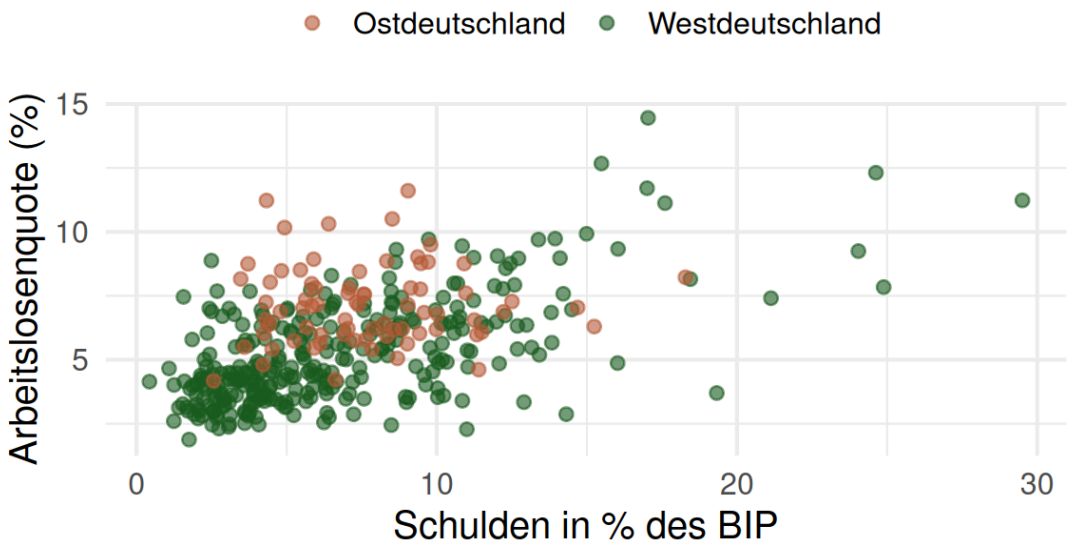
Chat AI, gefragt nach einer Interpretation des Streudiagramms:

> *"Die Korrelation von r = 0,55 belegt einen starken Zusammenhang:* ***Hohe Schulden verursachen Arbeitslosigkeit.*** *Steigt der Schuldenanteil um einen Prozentpunkt, steigt die Arbeitslosenquote um 0,55 Prozentpunkte. Dieser Zusammenhang gilt* ***für ganz Deutschland****."*

**3 Minuten, zu zweit:** Klingt kompetent. Finden Sie **drei** Fehler. Für einen davon brauchen Sie Code: Welchen?

03:00

# Bug Hunt 10: Prüfung




```
1 gesamtdaten |>
2   group_by(ost_name) |>
3   summarise(r = r_c(alo_quote, anteil_schulden))
```

```
# A tibble: 2 × 2
  ost_name            r
  <chr>           <dbl>
1 Ostdeutschland  0.0372
2 Westdeutschland 0.621
```

1. **“verursachen”:** Korrelation ist keine Kausalität. Arbeitslosigkeit kann ebenso Schulden verursachen (Sozialausgaben), oder ein Strukturwandel beides.
2. **“um 0,55 Prozentpunkte”:** r ist **keine Steigung**. Das leistet erst die Regression (nächstes Semester).
3. **“für ganz Deutschland”:** Im Osten gibt es praktisch **keinen** Zusammenhang. Die Gesamtkorrelation wird vom Westen getragen.

# Interpretation der Korrelation

- r hat **keine quantitative** Interpretation (“um wie viel?”)
- r misst nur **lineare** Zusammenhänge und reagiert auf Ausreißer
- Nützlich, um **stark korrelierte Variablen** zu finden. Das ist für die Regression wichtig (Stichwort *Multikollinearität*)

In Arbeiten steht meist eine **Korrelationsmatrix**:

```r
gesamtdaten |>
  select(alo_quote, anteil_schulden,
         bip_pro_kopf, wachstum) |>
  cor(use = "pairwise.complete.obs") |>
  round(2)
```

```
               alo_quote anteil_schulden bip_pro_kopf wachstum
alo_quote           1.00            0.55        -0.43     0.10
anteil_schulden     0.55            1.00        -0.06     0.12
bip_pro_kopf       -0.43           -0.06         1.00     0.02
wachstum            0.10            0.12         0.02     1.00
```

Nächstes Semester (Teil 3 der Case-Study): lineare Regression. Deren Koeffizienten lassen sich direkt interpretieren.

# Kahoot-Checkpoint 3: Grafiken, Karten, Korrelation

**kahoot.it** · PIN am Beamer

## 7 Fragen, 5 Minuten

- Log-Achse: Was heißt “parallel”?
- Bug Hunt 8: die Wachstumsrate
- Bug Hunt 9: die Lücke in den Klassen
- r aus dem Streudiagramm schätzen
- Schulden pro Kopf oder in % des BIP?
- Bug Hunt 10: Korrelation ≠ Kausalität ≠ Steigung
- Ost und West getrennt betrachten

Kahoot öffnen →

05:00

# Abschluss

# Checkliste: Tabellen und Grafiken prüfen

Bevor Sie eine Tabelle oder Grafik zeigen, egal ob von Chat AI oder von Ihnen:

**1. Kennzahl = Überschrift?** Mittel der Kreise oder Quote des Landes? (Bremen)

**2. Zähler und Nenner passen?** Gleiches Gebiet, gleiche Zählweise. (BH 6)

**3. Formel getestet?** Mit Zahlen, deren Ergebnis Sie kennen. (BH 8)

**4. Nichts per Hand abgezählt?** Zeilen über Inhalt wählen, nicht über Position. (BH 7)

**5. Klassen lückenlos?** `cut()` mit `Inf`, danach `count()`. (BH 9)

**6. Legende und Achsen gelesen?** Titel, Einheit, Log-Skala. (BH 9)

**7. Fehlendes erklärt?** Jedes `NA`, jeder abgeschnittene Wert in der Caption. (Stadtstaaten)

**8. Aussage gedeckt?** Korrelation ≠ Kausalität, und gilt sie für alle Gruppen? (BH 10)

Keiner der Bug Hunts in Teil 2 hat eine Fehlermeldung erzeugt.

# Zusammenfassung und Ausblick

**Was haben wir gelernt?**

- Daten **beschreiben**: Tabellen mit `skimr` und `kableExtra`
- Daten **zeigen**: Punkte + Boxplot, Zeitreihen, Histogramme, Karten, interaktive Grafiken
- **Zusammenhänge** quantifizieren: Korrelation, auch getrennt nach Gruppen
- **Prüfen:** Kennzahl, Nenner, Formel, Klassen, Legende, Aussage

**Was wir gesehen haben:** Ost und West unterscheiden sich auch 2024, 35 Jahre nach dem Mauerfall, deutlich. Aber auch im Westen gibt es Regionen mit hoher Arbeitslosigkeit und hohen Schulden.

**Dieses Semester:** deskriptive Statistik. **Nächstes Semester (Teil 3):** induktive Statistik und lineare Regression. Dann fragen wir, *wie stark* Schulden, BIP und Arbeitslosigkeit zusammenhängen, wenn wir andere Faktoren konstant halten.

# Prompting für Grafiken

Die Hinweise aus Teil 1 gelten weiter (Aufgabe, Instruktionen, Kontext; komplexe Aufgaben zerlegen). Für Grafiken zusätzlich:

- **Frage zuerst:** “Ich möchte zeigen, ob … Welcher Grafiktyp eignet sich?”
- **Daten mitgeben:** `glimpse()`-Output einfügen, dann rät Chat AI keine Spaltennamen
- **Gezielt nachbessern:** “Die Legende soll … heißen”, “Werte über 100.000 € abschneiden und in der Caption erwähnen”
- **Interpretation selbst schreiben** und dann von Chat AI prüfen lassen: *“Welche Aussagen in meinem Text sind durch die Grafik nicht gedeckt?”*

Chat AI schreibt Ihnen in Sekunden eine überzeugende Interpretation. Bug Hunt 10 zeigt, wie viel darin falsch sein kann.

# Hausaufgabe: Eigene Grafik erstellen

**Ziel:** Eine aussagekräftige Grafik zur **Einkommensverteilung** in Deutschland erstellen und interpretieren. **Start jetzt (5 Minuten):** Gruppen bilden und Fragestellung festlegen.

**Daten:** `einkommen.rds` im Repository (`case-study/data/`): durchschnittliches Einkommen je Arbeitnehmer (vgl. Übung zu Teil 1), Landkreise und Länder, 2000–2022.

1. **Gruppen** von 4–5 Personen
2. **Frage wählen:** Zeitreihe oder Querschnitt 2022? Was soll die Grafik zeigen?
3. **Grafik erstellen:** Inspiration in der R Graph Gallery und der Case-Study; Chat AI erlaubt
4. **Checkliste anwenden:** mindestens Punkte 1, 6 und 7 schriftlich beantworten
5. **Hochladen:** Code + Grafik + drei Sätze Interpretation über das Google-Formular
6. **Feedback-Runde** zu Beginn der nächsten Sitzung: anonymes Feedback von Kommiliton:innen und mir

05:00

# Anhang: Zum Selbststudium

# ✍️ Stadtstaaten-Join reparieren

`alo_lk` enthält Arbeitslose je Landkreis, `bip_2024` das BIP 2024 mit den Original-Schlüsseln aus der Excel-Datei. Passen Sie `bip_2024` **vor** dem Join so an, dass Hamburg und Berlin ein `bip_pro_kopf` bekommen.

Exercise | Start Over | Show Hint | ▷ Run Code

```
1  bip_2024_fix <- bip_2024
2
3  alo_lk |>
4    left_join(bip_2024_fix, by = "Regionalschluessel") |>
5    filter(landkreis_name %in% c("Hamburg", "Berlin", "Bremen"))
```

# ✍️ Ihr Bundesland hervorheben

Heben Sie statt Baden-Württemberg **ein anderes Bundesland** hervor, z.B. Ihr Heimatbundesland. Passen Sie auch den Untertitel an.

**Zusatz:** Zeichnen Sie mit `geom_hline()` den westdeutschen Median ein.

Exercise | Start Over | Show Hint | ▷ Run Code

```
gesamtdaten |>
  mutate(hervor = bundesland_name == "Baden-Württemberg") |>
  ggplot(aes(x = ost_name, y = alo_quote)) +
  geom_jitter(aes(colour = hervor), width = 0.25, height = 0, alpha = 0.6) +
  geom_boxplot(alpha = 0, outlier.shape = NA, width = 0.5) +
  scale_colour_manual(values = c("grey60", "#1b5e20"), guide = "none") +
  labs(subtitle = "Baden-Württemberg grün", x = NULL, y = "Arbeitslosenquote (%)") +
  theme_minimal()
```

# Arbeitslosigkeit, BIP und Schulden je Bundesland

| | Mittel und Streuung über die Landkreise | | | | | |
|---|---|---|---|---|---|---|
| | Arbeitslosenquote (%) | | BIP pro Kopf (€) | | Schulden pro Kopf (€) | |
| **Bundesland** | **Mittel** | **SD** | **Mittel** | **SD** | **Mittel** | **SD** |
| Bayern | 3,60 | 0,80 | 55.133 | 24.310 | 2.422 | 1.761 |
| Baden-Württemberg | 4,10 | 0,83 | 55.750 | 18.616 | 3.461 | 2.721 |
| Hessen | 5,50 | 1,28 | 52.582 | 22.246 | 4.329 | 3.815 |
| Rheinland-Pfalz | 5,84 | 1,52 | 43.915 | 15.810 | 2.666 | 2.586 |
| Schleswig-Holstein | 5,98 | 0,80 | 43.454 | 10.333 | 3.530 | 1.474 |
| Niedersachsen | 6,18 | 1,77 | 46.411 | 26.052 | 2.757 | 1.890 |
| Saarland | 6,33 | 1,85 | 38.998 | 9.228 | 5.136 | 1.124 |
| **Sachsen** | **6,47** | **0,88** | **38.130** | **7.508** | **2.556** | **1.179** |
| **Thüringen** | **6,68** | **1,64** | **35.495** | **7.258** | **2.827** | **637** |
| **Brandenburg** | **7,06** | **1,63** | **40.426** | **9.206** | **2.457** | **1.313** |
| Nordrhein-Westfalen | 7,36 | 2,33 | 45.915 | 14.358 | 4.846 | 2.613 |
| **Mecklenburg-Vorpommern** | **7,94** | **1,20** | **39.548** | **8.745** | **4.393** | **2.267** |
| **Sachsen-Anhalt** | **8,09** | **1,48** | **36.335** | **5.195** | **3.121** | **1.730** |

*Bitte beachten:*

Ohne Stadtstaaten (keine Schuldendaten). Ostdeutsche Bundesländer grau hinterlegt.

> Was lernen wir aus dieser Tabelle? Und warum steht oben “über die **Landkreise**”?

# Arbeitslosenquote, BIP und Schulden: beschrieben

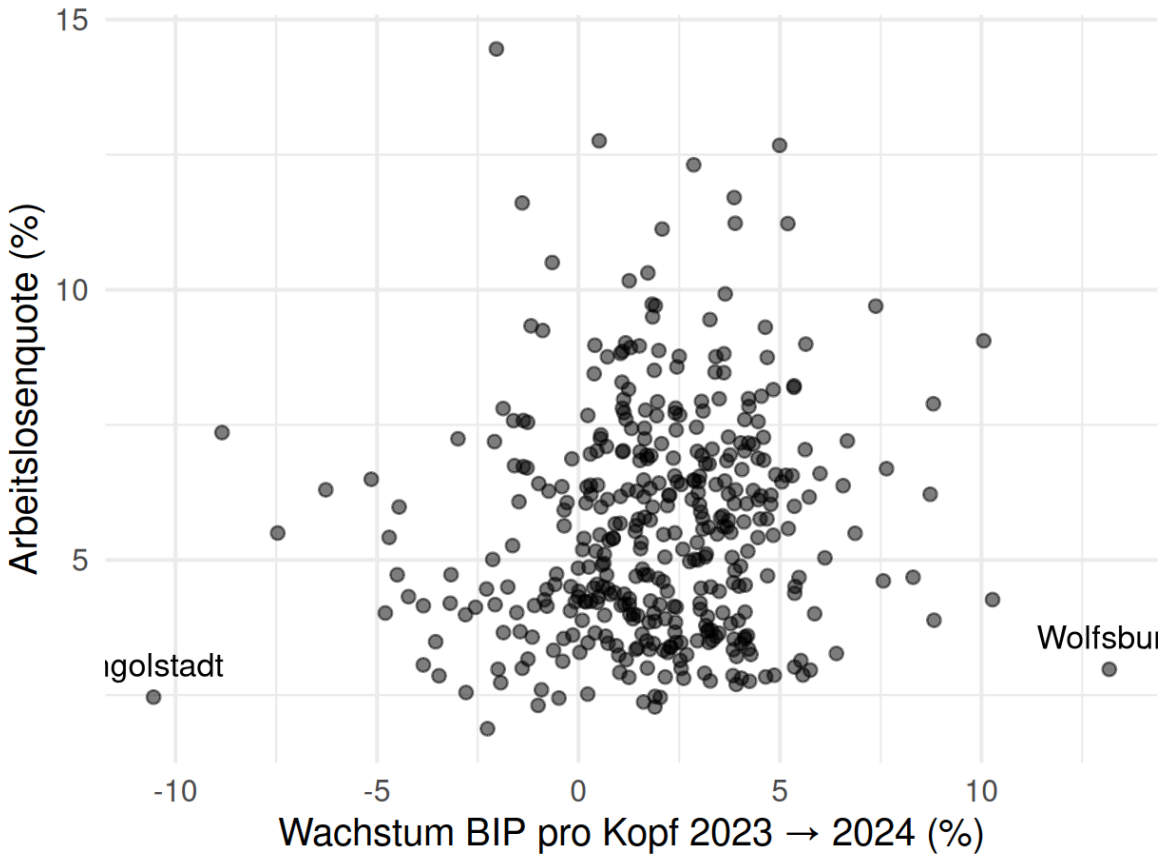
- Länder mit **niedriger** Arbeitslosigkeit haben im Mittel ein **hohes** BIP pro Kopf (Bayern, Baden-Württemberg, Hessen)
- Ostdeutsche Landkreise: BIP pro Kopf im Mittel **unter 41.000 €**. Die Grenze verschwimmt aber: Das Saarland liegt unter Brandenburg
- Bei den **Schulden** gibt es kein Ost-West-Muster: Bayern, Brandenburg und Sachsen niedrig; Saarland, NRW, Mecklenburg-Vorpommern und Hessen hoch

**Allein mit Mittelwert und Standardabweichung lernen wir schon viel über regionale Unterschiede. Ob sie *zusammenhängen*, klären wir mit Grafiken und Korrelationen.**



Auch Zeitreihen passen in Tabellen. Ein Beispiel mit dem Paket `gt` (BIP pro Kopf 1992, 2007, 2024 je Bundesland) finden Sie in der ausformulierten Case-Study.

# Arbeitslosigkeit und BIP-Wachstum




🔮 Positiv, negativ oder kein Zusammenhang?

```
1  cor(gesamtdaten$alo_quote, gesamtdaten$wachstum)
```

```
[1] 0.09867344
```

- **Praktisch kein** Zusammenhang
- Die Ausreißer sind Einzelunternehmen: Wolfsburg (VW) wächst, Ingolstadt (Audi) schrumpft
- Ein einzelnes Jahr Wachstum sagt wenig über die Lage am Arbeitsmarkt